

컴퓨터비전(AI 응용)

이미지 캡셔닝

이미지 캡셔닝의 핵심 원리를 이해하고, 직접 모델을 구현하여 결과를 분석하는 전 과정을 경험합니다.



원리 이해 (Understanding)

CNN과 LSTM을 활용한 **이미지 특징 추출** 및 **시퀀스 생성** 원리를 이해한다.



모델 구현 (Implementation)

이미지-텍스트 페어 데이터셋을 활용해 **CNN+LSTM 모델을 구축**하고 학습할 수 있다.



평가 및 개선 (Evaluation)

학습된 모델의 **성능을 평가**하고, 결과 캡션을 해석하여 모델을 개선할 수 있다.

이미지 캡셔닝이란?

시각적 정보 이해와 언어적 표현 능력이 융합된 **멀티모달(Multi-modal)** AI의 대표적인 기술입니다.



기술 정의

입력된 이미지의 내용을 분석하여 상황을 가장 잘 설명하는 **자연어 문장을 자동 생성**하는 AI 기술임.



생성 예시

"검은색 털을 가진 **강아지**가 나무 **마루** 위에 **얌전히 앉아 있다.**"와 같이 구체적인 문장을 출력함.



CV + NLP 융합

Computer Vision(보는 능력)과 **NLP**(말하는 능력)의 결합으로, 시각 정보와 언어 표현이 동시에 필요함.



핵심 가치



접근성 (Accessibility)

정보 격차 해소



검색성 (Searchability)

데이터 탐색 효율



자동화 (Automation)

비용 절감 및 효율화



시각장애인 보조 기술

화면을 볼 수 없는 사용자에게 주변 상황이나 웹 이미지를 **음성으로 설명(Alt Text)**해 주어 디지털 및 물리적 접근성을 획기적으로 높입니다.




사진 관리 및 스마트 검색

개인 클라우드나 스톡 사이트에서 **자동 태깅 및 설명 생성**을 통해, 사용자가 텍스트 검색만으로 원하는 장면을 찾을 수 있게 합니다.



전자상거래 업무 자동화

수많은 상품 이미지에 대해 **기본 상세 설명과 해시태그를 자동 생성**하여, 마케터와 셀러의 반복 업무 시간을 단축시킵니다.



의료 및 산업 현장 분석

X-ray/MRI 판독문의 초안을 작성하거나, CCTV 영상의 **이상 상황을 텍스트로 요약**하여 전문가의 신속한 의사결정을 돕습니다.

CNN + LSTM 전체 파이프라인 한 눈에 보기

이미지 입력부터 캡션 생성까지의 데이터 흐름을 단계별로 확인합니다.




그림 2.1 CNN-LSTM 아키텍처 예제

CNN + LSTM 전체 파이프라인 한 눈에 보기

이미지 입력부터 캡션 생성까지의 데이터 흐름을 단계별로 확인합니다.

Computer Vision (Encoder)



입력 이미지

Pixel Data
(3, H, W)



CNN 특징 추출

ResNet / VGG
Convolution



특징 벡터

Embedding
Compression



LSTM 디코딩

Sequence Model
Memory Cell



최종 문장

"강아지가 마루에
앉아 있다"



학습 (Training)

실제 정답 캡션을 입력으로 주어, 모델이 예측한 단어와의 오차(Loss)를 최소화하는 방향으로
CNN과 LSTM의 가중치를 업데이트합니다.




추론 (Inference)

이미지만 입력받아 <start> 토큰부터 시작해 <end> 토큰이 나올 때까지 단어를
하나씩 순차적으로 생성합니다.

이미지의 시각적 정보를 컴퓨터가 이해할 수 있는 벡터 형태로 변환합니다.

ARCHITECTURE VIEW



i Pre-trained Model 사용 (예: ResNet-101, VGG-16)

💡 Transfer Learning:
보통 ImageNet 등으로 미리 학습된(Pre-trained) 모델의 가중치를 가져와 인코더로 사용하면 성능이 훨씬 좋습니다.

특징 추출의 핵심 원리

사람이 이미지를 보고 "강아지", "풀밭"을 인식하듯,
CNN은 이미지의 픽셀 데이터에서 **추상적인 시각적 패턴**을 찾아냅니다.

- ✓ **입력 이미지 압축**
고해상도 이미지를 처리 가능한 크기로 줄이면서,
중요한 정보(객체의 유무, 위치 등 특징)를 보존합니다.
- ✓ **합성곱 연산 (Convolution)**
필터(Filter)를 사용해 에지(Edge), 텍스처, 사물의 형태 등을
단계적으로 검출합니다.
- ✓ **벡터화 (Embedding)**
CNN의 마지막 완전 연결 계층(Full Layer) 직전의 출력을 사용하여, 이미지를
고정된 길이의 **숫자 배열(Feature Vector)**로 변환합니다.

즉, CNN의 마지막 계층의 출력이 **특징 벡터(feature vector)**로 사용

CNN 레이어가 깊어질수록 단순한 형태에서 의미 있는 사물로 인식이 고도화됩니다.



EARLY LAYERS

1단계: 선과 경계

가장 앞단의 합성곱 층은
이미지의 **명암 변화**나 **에지(Edge)**,
단순한 직선과 곡선을 감지합니다.
(Filter와 유사)



MIDDLE LAYERS

2단계: 질감과 패턴

선들이 조합되어 만들어진
줄무늬, 격자, 점박이 등의
복잡한 질감(Texture)과 패턴 정보를 학습합니다.
(부분적인 모양 형성)



DEEP LAYERS

3단계: 사물 형태

눈, 바퀴, 손잡이와 같이
의미 있는 사물의 부분(Parts)이나
전체 객체(Objects)의 형태를 인식합니다.
(추상화 완료)

Low Level Feature

Abstraction Level (추상화 수준)

High Level Feature

CNN이 추출한 시각적 특징을 바탕으로 자연어 문장을 순차적으로 생성합니다.

핵심 메커니즘



장기 기억 (Long-Term)

긴 문맥 정보 유지



순차 처리 (Sequential)

이전 단어 기반 예측



언어 모델링 (Language)

자연스러운 문장 완성



CNN 특징 벡터 입력

CNN 인코더의 **마지막 계층에서 출력된 특징 벡터(Feature Vector)**가 LSTM의 초기 입력으로 전달되어, 이미지의 전체적인 시각적 내용을 모델에 주입합니다.



순차적 단어 예측

LSTM은 이전 단계의 정보(Hidden State)와 현재 단어를 기반으로 **다음 단어가 나타날 확률**을 계산하여 가장 적절한 단어를 하나씩 예측합니다.



Start / End 토큰 처리

문장 생성을 시작하기 위해 **<start>** 토큰을 입력하고, 모델이 **<end>** 토큰을 예측하면 문장 생성을 종료합니다.

- CNN이 만든 특징 벡터를 입력으로 받아, 순차적으로 단어를 예측하며 문장을 생성함.
- LSTM(Long Short-Term Memory)은 시퀀스 데이터를 처리하는 RNN 계열 모델
- 이전 단어의 정보를 기억하면서 다음 단어를 예측함.
- "<start>" 토큰으로 문장을 시작하고, 단어를 하나씩 생성하다가 "<end>" 토큰에서 종료함.

```
<start> PyTorch is a deep learning library. <end>
```


그러면 각 단어/토큰을 다음과 같이 숫자에 매핑한다.

```
<start> : 0  
PyTorch : 1  
is : 2  
a : 3  
deep : 4  
learning : 5  
library : 6  
. : 7  
<end> : 8
```

컴퓨터는 문장을 어떻게 이해할까?

자연어 문장을 컴퓨터가 연산 가능한 숫자의 나열(Vector)로 변환하는 과정입니다.

변환 프로세스 (Transformation Flow)




단어 사전 (Vocabulary) 예시

인덱스 (ID)	토큰 (Token)	설명
0	<pad>	길이 맞춤용 (Padding)
1	<start>	문장 시작 알림
2	<end>	문장 종료 알림
3	<unk>	모르는 단어 (Unknown)
...	...	
12	가	조사
45	강아지	명사
89	공	명사
102	문다	동사

모델은 어떻게 배우나?

정답을 알려주며 가르치는 Teacher Forcing과 오차를 줄이는 역전파 과정을 이해합니다.



Teacher Forcing (교사 강요)

학습 초기에는 모델이 예측한 단어가 틀릴 확률이 높습니다.
따라서 이전 시점의 '예측값' 대신 실제 '정답(Ground Truth)'을 입력으로 넣어주어
학습 속도와 안정성을 높이는 기법입니다.



Cross-Entropy Loss (교차 엔트로피)

모델이 예측한 단어의 확률 분포와 실제 정답 단어(One-hot vector) 간의 차이를 계산합니다.
이 손실(Loss)을 최소화하는 방향으로 미분(Gradient)을 계산해 파라미터를 업데이트합니다.

추론 전략: Greedy vs Beam Search

모델이 다음 단어를 선택할 때 사용하는 두 가지 주요 전략의 차이점을 비교합니다.



Greedy Search

STEP-BY-STEP MAX



매 순간 확률 1등만 선택

작동 원리

현재 시점에서 확률이 가장 높은 단어 1개만을 선택하여 다음 단계로 진행합니다.

장점: 속도와 효율성

계산 비용이 매우 적고 추론 속도가 빠릅니다. 메모리 사용량도 최소화됩니다.

단점: 국소 최적해(Local Optima)


지금 당장은 최선이지만, 전체 문장 관점에서는 어색한 결과를 낼 수 있습니다. 한 번 잘못 선택하면 되돌릴 수 없습니다.

VS



Beam Search

TOP-K CANDIDATES



상위 K개 후보(Beam Width)를 유지

작동 원리

매 시점 상위 k개의 유망한 경로를 유지하며 탐색합니다. 최종적으로 누적 확률이 가장 높은 문장을 선택합니다.

장점: 품질 향상

전체적인 문맥을 고려하여 더 자연스럽게 정확한 캡션을 생성합니다. 국소 최적해 위험이 줄어듭니다.

단점: 계산 비용

K배 만큼의 메모리와 연산 시간이 더 필요합니다. (속도와 품질의 트레이드오프)



실무 Tip: Beam Width 설정


일반적인 이미지 캡셔닝 태스크에서는 Beam Width (k) = 3 ~ 5 정도가 적절합니다. k가 너무 크면 오히려 일반적인 문장(Generic Sentence)만 생성되거나 성능 향상폭이 미미해질 수 있습니다.

Attention: 어디를 보고 말하나?

모델이 단어를 생성할 때마다 이미지의 관련 영역에 집중(Attend)합니다.

ATTENTION MAP VIEW

Generating word: **"Frisbee"**



Context Vector

인간의 시각 인식 모방

사람이 "강아지가 공을 문다"라고 말할 때, '공'을 말하는 순간 시선이 공을 향하는 것과 같은 원리입니다.



동적 가중치 (Dynamic Weights)

LSTM의 매 시점(Time Step)마다 이미지의 각 픽셀 영역(Feature map grids)에 대해 중요도를 다르게 계산합니다.



성능 및 정확도 향상

모든 정보를 하나의 벡터에 압축하던 기존 방식의 **정보 손실 문제**를 해결하여 긴 문장 생성에 유리합니다.



설명 가능성 (Interpretability)


모델이 캡션을 생성할 때 이미지의 어느 부분을 보고 판단했는지 시각화(Heatmap)하여 분석할 수 있습니다.




Soft vs Hard Attention:

모든 영역을 확률적으로 보는 **Soft Attention**(미분 가능)이 **Hard Attention**(특정 영역만 선택)보다 학습에 더 널리 사용됩니다.

이미지 입력부터 최종 문장이 완성되기까지의 4단계 프로세스를 확인합니다.



> 생성 예시 (Example Scenario)



모델은 학습 과정에서 실제 캡션을 입력받아 예측 단어와 비교하며 손실을 최소화함.

성능 평가 지표 (Metrics)

생성된 캡션이 정답 문장과 얼마나 유사한지 수치화하여 평가합니다.



BLEU

Bilingual Evaluation Understudy

기계 번역 분야의 표준 지표로,
생성된 문장과 정답 문장 간의 **n-gram 정밀도(Precision)**
를 측정합니다.

- ✓ 연속된 단어(n-gram)가 얼마나 일치하는지 확인
- ✓ 짧은 문장에 페널티 부여 (Brevity Penalty)
- ! 단순 매칭이라 동의어나 문맥 고려 부족



METEOR

Metric for Evaluation of Translation

BLEU의 단점을 보완하여 **정밀도와 재현율**의 조화 평균을
사용하며, 유의어까지 고려합니다.

- ✓ 동의어 매칭 및 어간 추출(Stemming) 지원
- ✓ 사람의 평가(Human Judgment)와 높은 상관관계
- ✓ 문법적인 유창성 평가에 유리함



CIDEr

Consensus-based Image Description
Evaluation

이미지 캡셔닝에 특화된 지표로, TF-IDF 가중치를 사용하여
중요 단어의 일치 여부를 봅니다.

- ✓ 다수의 정답 캡션 집합(Consensus)과의 유사도
- ✓ 자주 등장하지 않는 '핵심 단어'에 높은 가중치
- ★ 현재 캡셔닝 대회(COCO 등)의 주요 평가 기준



💡 실습 팁: 과적합(Overfitting) 모니터링

모델 학습 시 Loss 값만 보지 말고, 검증 데이터셋(Validation Set)에 대한 **CIDEr 점수**를 주기적으로 확인하세요.
Loss는 줄어드는데 CIDEr 점수가 정체되거나 떨어지면 학습을 중단(Early Stopping)해야 합니다.

☰ 단계별 수행

총 4단계



STEP 01 데이터 전처리 파이프라인 구축

이미지 리사이징(224x224), 캡션 토큰화(<start>, <end> 추가), 단어 사전(Vocabulary) 생성 코드를 작성합니다.



STEP 02 모델 아키텍처 구현 (CNN + LSTM)

Pre-trained ResNet을 인코더로, LSTM을 디코더로 하는 `CaptionModel` 클래스를 정의합니다.



STEP 03 학습 루프 및 검증

CrossEntropyLoss를 사용하여 모델을 학습시키고, Epoch마다 Validation Loss가 감소하는지 확인합니다.



STEP 04 결과 시각화 및 분석

테스트 이미지 5장에 대해 캡션을 생성하고, 이미지를 시각화하여 생성된 문장이 적절한지 평가합니다.