

컴퓨터비전(AI응용)

설명가능한 인공지능(XAI)



왜(Why)를 이해하기

블랙박스 AI의 문제를 인식하고,
설명 가능한 AI(XAI)가 왜 필수적인지 설명할 수 있습니다.




핵심 직관 익히기

CAM, Saliency Map 등 4가지 주요 기법의 작동 원리를
복잡한 수식 없이 직관적으로 이해합니다.



상황별 선택 능력

데이터 유형과 목적(속도 vs 신뢰)에 따라
적합한 XAI 기법을 선택할 수 있습니다.



SECTION 1

XAI 개요

블랙박스 문제와 신뢰성

SECTION 2

CAM / Grad-CAM

"어디를 보고 판단했나?" (위치 중심)

SECTION 3

Saliency Map

"픽셀 변화의 민감도" (미세 변화)

SECTION 4

Integrated Gradients

"경로를 따라 누적된 기여도" (신뢰성)

SECTION 5

종합 비교 및 정리

기법 선택 가이드 및 퀴즈

XAI 가 왜 필요한가?

AI의 판단 근거를 모르면 신뢰할 수 없습니다.
설명 가능성은 **신뢰(Trust)**의 핵심입니다.



의료 진단

"왜 암이라고 판단했나요?"
의사가 병변 위치를 확인해야 진단 결과 신뢰



대출 심사

"왜 거절되었나요?"
투명한 사유 설명이 있어야 고객 이의 제기 가능




자율 주행

"왜 급정거했나요?"
사고 발생 시 원인 추적과 책임 소재 규명

신뢰도와 설명 가능성의 관계

AI 신뢰도 (Trust)



블랙박스 AI vs 설명가능한 AI

왜 우리는 결과를 넘어 '과정'을 이해해야 하는가?

비교 항목	블랙박스 AI (기존)	설명 가능한 AI (XAI)
이해도 (Understandability)	내부 동작을 알 수 없음. 입력과 출력만 확인 가능.	결과의 근거(Feature Importance, Heatmap 등)를 시각적으로 제공.
신뢰 및 책임 (Trust & Accountability)	오작동 시 원인 파악이 어려워 책임 소재가 불분명함.	의사결정 경로 추적이 가능하여 오류 수정 및 책임 규명 용이.
규제 및 감사 (Regulation & Audit)	설명 요구에 대응하기 어려움	법적 규제 준수 및 감사 보고서 작성에 유리.
사용자 수용성 (User Acceptance)	맹목적인 믿음 강요 ("AI가 그렇다니까 믿으세요")	납득 가능한 이유 제시 ("이 부분 때문에 암으로 진단했습니다")



의료 및 헬스케어

AI가 진단한 질병의 원인을 **히트맵(Heatmap)**으로 시각화하여 의료진의 판독을 보조하고 환자에게 근거를 설명합니다.



금융 및 신용 평가

대출 심사 거절 시, '소득 수준'이나 '연체 기록' 등 **결정적 요인**을 제시하여 고객의 알 권리를 보장합니다.



제조 및 품질 관리

제품 불량 판정 시, AI가 이미지 상의 **어떤 결함이나 흠집**에 주목했는지 표시하여 공정 개선을 돕습니다.



자율주행 자동차

장애물 인식 및 회피 결정 시, 센서 데이터의 **중요 객체(보행자, 신호등)**를 식별해 사고 시 원인을 분석합니다.



리테일 및 추천 시스템

"고객님이 지난달 구매한 **운동화와 유사한 스타일**이라 추천했습니다"와 같이 추천한 이유 설명함




공공 및 법률

복지 수급자 선정이나 범죄 예측 모델의 결과에 대해 **공정성**을 검증하고 행정 투명성을 확보함

CAM: 형광펜으로 중요한 부분 표시하기

AI 모델이 이미지의 **어디를 보고** 이 정답을 선택했는지 시각적으로 보여줍니다.



Legend

● 입력/일반 영역

● 관련 있음

● 매우 중요 (결정적 근거)

이미지 인식 모델(CNN)은 어떻게 중요한 위치를 찾아낼까요?




💡 **핵심 포인트:** CAM은 "어떤 특징(Feature)"이 "얼마나 중요(Weight)"한지를 결합하여 위치 정보를 복원하는 기술입니다.

한계를 극복하고 더 범용적인 설명으로 나아가는 과정

비교 항목	 CAM	 Grad-CAM
필요 조건 (Prerequisites)	구조 변경 필수 CNN 끝단에 GAP 레이어가 반드시 있어야 함. (재학습 필요)	구조 변경 없음 이미 학습된 대부분의 CNN 모델에 즉시 적용 가능.
핵심 아이디어 (Key Idea)	GAP 레이어의 가중치(Weight) 를 사용하여 특징맵 결합	역전파된 기울기(Gradient) 정보를 사용하여 중요도 계산
해석력 (Interpretability)	특정 클래스를 판단하는 데 중요한 위치 를 히트맵으로 표시	CAM과 동일하게 위치를 표시하되, 적용 범위가 훨씬 넓음
한계점 (Limitations)	모델 구조를 바꿔야 해서, 이미 배포된 모델에는 쓰기 어려움	픽셀 단위의 아주 세밀한 경계선은 여전히 흐릿할 수 있음

CAM 구조


Conv → **GAP** → Softmax



특수 레이어(GAP)가 꼭 필요함

Grad-CAM 구조

Conv ◀ **Gradient** ▶ FC Layer



어떤 구조든 기울기만 있으면 OK!

CAM

- CNN 구조에서 **마지막 합성곱층 → Global Average Pooling(GAP) → FC layer** 순으로 연결된 경우 활용 가능함
- GAP 계층을 통해 각 특징맵(feature map)을 평균화 >> FC 계층의 가중치(weights)를 곱해 >> 각 특징맵이 특정 클래스에 기여한 정도를 바탕으로 히트맵(heat-map)을 생성함.
- 히트맵을 통해 “모델이 어떤 공간적 위치에서 해당 클래스로 판단했는가” 를 시각화

Grad-CAM

- CAM의 구조적 제약(GAP+FC) 없이 **기존의 CNN 구조에 재학습 없이 바로 적용 가능**함.
- 특정 클래스 c 에 대한 출력 y_c (softmax 직전) 를 기준으로,
 - >> 마지막 합성곱 층의 각 특징맵 A^k 에 대해 **기울기**를 계산함.
- 그 기울기 값들을 공간 축 전체에 합산해 각 특징맵의 **importance weight** α^k 를 얻음.
- 이 α^k 와 특징맵 A^k 의 가중합을 통해 히트맵을 얻고,
ReLU 활성화를 적용해 **positive 영향 영역** 만을 강조함



한 줄 요약

CAM과 Grad-CAM은 AI가 판단을 내릴 때 **이미지의 어디를(Where) 중요하게 보았는지**를 히트맵으로 시각화합니다.

어디를(Where)



왜 중요한가?

신뢰와 검증의 핵심 도구입니다.

의료 진단:

AI가 실제 폐렴 병변 위치를 보고 판단했는지 의사가 확인 가능

제조 결함 탐지:

제품의 스크래치 위치를 정확히 지적했는지 검증




흔한 오해

✖ 오해

"Grad-CAM이 항상 CAM보다 더 선명하다?"

✔ 사실: 아닙니다.

Grad-CAM은 구조적 제약을 없앤 범용성이 장점입니다.
선명도는 주로 **마지막 특징맵의 크기**에 좌우함



<https://www.geeksforgeeks.org/machine-learning/what-is-saliency-map/>

Saliency Map: 민감도(Sensitivity) 검사

핵심 질문

"입력 이미지의 픽셀을 **아주 조금 바꿨을 때**,
AI의 예측 결과가 **얼마나 크게 변하는가?**"



1. 전처리 (Preprocessing)

입력 이미지를 모델에 맞는 형태로 변환



2. 기울기 계산 (Gradient Calculation)


역전파(Backpropagation)를 통해 각 픽셀의 미분값(기울기) 계산



3. 시각화 (Visualization)

기울기의 절댓값을 취해 이미지 형태의 지도(Map)로 표현

Saliency Map 작동 예시



색상 범례 (Color Legend)



영향력 낮음 (Low Sensitivity)

영향력 높음 (High Sensitivity)

- 입력 이미지의 각 픽셀이 모델 출력에 얼마나 영향을 주는지 시각화하는 기법.
- 출력 확률을 기준으로 입력 픽셀의 기울기(**gradient**)를 계산함.
- 단순하지만 노이즈가 많고, 해석력이 떨어지는 단점이 있음.
- “모델이 어디를 보고 판단했는가?”를 기본적으로 보여줌.

Saliency Map의 장점과 단점

👍 장점 (Pros)

빠르고 간단함

모델 구조를 변경할 필요 없이 역전파(Backpropagation) 1회 계산만으로 즉시 결과를 얻을 수 있습니다.

전역적 민감도 파악

입력 이미지의 모든 픽셀에 대해 각각 얼마나 결과에 영향을 미치는지 세밀하게(Pixel-level) 확인할 수 있습니다.

👎 단점 (Cons)

노이즈에 민감


결과물이 마치 지직거리는 TV 화면처럼 산만하게 보일 수 있어, 직관적인 해석이 어려울 때가 많습니다.

기울기 소실 및 포화


이미지 픽셀 값이 조금 변해도 예측값이 변하지 않는 구간에서 중요도가 0으로 잘못 표시될 수 있습니다.

결과 해석: 원본 vs Saliency Map

입력 이미지의 각 픽셀이 결과에 **얼마나 민감한지** 시각화합니다.



기울기(Gradient) 계산
Backpropagation



■ **붉고 밝은 영역:** 모델이 판단에 결정적으로 사용한 픽셀입니다. (예: 강아지의 눈, 코)

■ **어두운 영역:** 결과에 영향을 거의 주지 않는 부분입니다.

주의: 배경의 노이즈가 강조되어 보일 수 있으니 전체적인 형태를 봐야 합니다.

💡 섹션 3 핵심 요약

한 줄 요약 "입력을 아주 조금 바꿨을 때 결과가 흔들리는 곳을 찾는다."

중요성 모델 수정 없이 즉시 적용 가능하여 빠른 1차 진단에 유리합니다.

흔한 오해 "Map이 선명하다고 모델 성능이 좋은 건 아닙니다." (오히려 과적합 신호일 수도 있음)

Integrated Gradients: 등산하듯 누적하기

한 지점의 기울기만 보는 대신,
출발점부터 도착점까지의 모든 기울기를 더합니다.



1. Baseline (산 입구)

정보가 없는 상태(예: 검정색 이미지)에서 시작합니다.
"아무런 특징도 없는 0의 상태"



2. 경로 (Path)

Baseline에서 실제 이미지(정상)까지 조금씩 픽셀값을
변화시키며 이동합니다.
"이미지가 서서히 밝아지는 과정"



3. 누적 (Integration)

이동하는 모든 순간의 기울기(중요도)를 합산하여
최종 기여도를 계산합니다.
"모든 발자국을 더하면 높이가 된다"

- 딥러닝 모델의 출력에 대한 입력 특징(feature)의 기여도를 정량적으로 계산하는 해석 기법임.
- 입력값과 기준값(예: 모든 0 이미지) 사이를 잇는 선형 경로를 따라 기울기(gradient)를 누적적으로 적분함.
- 각 입력 특징이 모델 결과에 얼마나 영향을 주었는지를 계산해 모델의 결정 근거를 시각적으로 설명함.
- Saliency Map보다 노이즈가 적고, 이론적으로 일관성(Completeness)이 보장됨.
- 이미지 분류나 탭 데이터 등에서 특징 중요도 분석(feature importance analysis)에 활용됨.

Baseline 선택과 완전성(Completeness)

"무엇과 비교할 것인가?"가 설명의 시작입니다.

📍 Baseline(기준점) 예시



이미지 (Image)

완전한 검정색(0) 또는 노이즈 이미지



텍스트 (Text)

의미 없는 토큰(Embedding=0)이나 패딩

Baseline은 '정보가 없는 상태'여야 합니다.
기준점이 잘못되면 결과 해석도 왜곡될 수 있습니다.

완전성 속성 (케이크 비유)



딸기
(특성 A)

+

밀가루
(특성 B)

=

케이크 맛
(전체 예측)

"재료들의 기여도를 모두 더하면,
결국 케이크 전체의 맛 점수가 되어야 한다."

$$\Sigma (\text{특성 기여도}) = f(\text{입력}) - f(\text{Baseline})$$


"출발점(Baseline)과 도착점(입력) 사이의 예측값 차이는
각 특성이 기여한 값들의 총합과 같다."

Saliency Map vs Integrated Gradients

"순간의 기울기"와 "누적된 기울기"의 차이

비교 항목	⚡ Saliency Map	⚠ Integrated Gradients
원리 (Principle)	로컬 기울기 (Local Gradient) 현재 입력값에서의 민감도만 측정	누적 기울기 (Path Integral) Baseline에서 입력값까지의 경로 적분
장점 (Pros)	계산이 매우 빠름 (1회 역전파) 직관적인 민감도 해석	기울기 포화(Saturation) 문제 해결 이론적 완전성(Completeness) 보장
단점 (Cons)	시각적 노이즈가 많음 기울기 소실 시 중요도 0으로 오해	계산 비용 높음 (수십 번 반복 계산) 적절한 Baseline 설정 필요
적합 상황	빠른 스캔 실시간 처리가 필요하거나 대략적 파악 시	정밀 분석 높은 신뢰도와 규제 대응이 필요할 때

📌 경로 누적 (Path Integral)



Baseline에서 실제 입력까지 변하는 모든 기울기를 더합니다.

✔ Section 4 요약

한 줄 요약

IG는 '결과'뿐만 아니라 '과정' 전체의 기여도를 공정하게 배분

왜 중요한가?

Saliency Map이 놓칠 수 있는 정보(포화된 기울기)를 복원해 신뢰도를 높입니다.

4가지 XAI 기법 종합 비교

기법	작동 원리	장점 (Pros)	단점 (Cons)	적합한 상황	계산 속도	설명 신뢰감
CAM Class Activation Mapping	마지막 특징맵과 가중치 의 선형 결합 으로 위치 파악	✓ 매우 직관적 ✓ 위치 정보 정확	✗ 특정 구조(GAP) 필수 ✗ 낮은 해상도	간단한 CNN 모델 구조, 대략적 위치 파악 시	보통	보통
Grad-CAM Gradient-weighted CAM	기울기(Gradient) 정보를 활용해 중요도 가중치 계산	✓ 모델 구조 제약 없음 ✓ 높은 범용성	✗ 픽셀 단위 세밀함 부족 ✗ 기울기 소실 가능성	이미 학습된 다양한 모델, 일반적인 시각화 용도	보통	보통
Saliency Map Sensitivity Analysis	입력 이미지에 대한 출력의 기울기 (민감도) 를 직접 계산	✓ 구현이 가장 간단 ✓ 픽셀 단위 확인 가능	✗ 노이즈가 심함 ✗ 사람이 보기 난해함	빠른 모델 디버깅, 미세 변화 감지 필요 시	빠름	낮음
Integrated Gradients	Baseline부터 입력까지 경로를 따라 기울기를 적분(누적)	✓ 이론적으로 탄탄함 ✓ 포화 문제 해결	✗ 계산 비용이 높음 ✗ Baseline 설정 필요	금융/의료 등 고신뢰 분야, 규제 대응 및 정밀 분석	느림	높음

● 장점 영역 ● 단점/주의 영역

상황에 따라 빠른 확인(Saliency)과 신뢰성(IG) 사이에서 균형을 잡는 것이 중요합니다.

어떤 기법을 언제 써야 하나요?





CAM / Grad-CAM

위치 시각화

"이미지의 **어디**를 봤니?"
히트맵으로 중요 영역 표시



Saliency Map

민감도 분석

"얼마나 **민감**하게 반응하니?"
픽셀 변화에 따른 결과 변동



Integrated Gradients

누적 기여도

"과정 전체를 **누적**했니?"
Baseline부터의 변화량 합산



XAI의 목표

신뢰와 책임

"결과를 **믿을 수** 있니?"
블랙박스 해소를 통한 투명성

한 줄 요약

XAI는 복잡한 AI 모델의 의사결정 과정을 시각화하고 설명하여, 인간이 이해하고 검증할 수 있게 만드는 기술입니다.

핵심:

결과(What) + 이유(Why) = 신뢰(Trust)

왜 중요한가?

- ✓ **의료/금융:** 고위험 결정의 근거 확보
- ✓ **법적 규제:** 설명 요구 권리(GDPR) 대응
- ✓ **모델 개선:** 오류 원인 파악 및 디버깅

흔한 오해

Misconception

"설명이 그럴싸하면 정답이다?"

No. 모델이 틀린 이유를 설명할 수도 있습니다.
XAI는 모델의 '생각'을 보여주는 것이지,
현실의 진실을 보장하는 것은 아닙니다.