

설명 가능한 AI(XAI)

1. XAI 개요

▶ 수업 목표

- 딥러닝 모델의 입력 특징이 예측 결과에 미치는 영향을 정량적으로 설명하는 방법을 이해함.
- Integrated Gradients의 수학적 원리(기준 입력과 기울기 적분 개념)를 파악함.
- Saliency Map 등 기존 시각화 기법과 비교하여, Integrated Gradients의 장단점과 활용 사례를 설명할 수 있음.

설명 가능한 AI(XAI)

2. CAM/Grad-CAM

▶ CAM

- CNN 구조에서 마지막 합성곱층 → Global Average Pooling(GAP) → FC layer 순으로 연결된 경우 활용 가능함
- GAP 계층을 통해 각 특징맵(feature map)을 평균화하고, FC 계층의 가중치(weights)를 곱해 각 특징맵이 특정 클래스에 기여한 정도를 바탕으로 히트맵(heat-map)을 생성함.
- 히트맵을 통해 “모델이 어떤 공간적 위치에서 해당 클래스로 판단했는가” 를 시각화 할 수 있음

▶ Grad-CAM

- CAM의 구조적 제약(GAP+FC) 없이 기존의 CNN 구조에 재학습 없이 바로 적용 가능함.
- 특정 클래스 c 에 대한 출력 y_c (softmax 직전) 를 기준으로, 마지막 합성곱층의 각 특징맵 A^k 에 대해 기울기를 계산함.
- 그 기울기 값들을 공간축 전체에 합산해 각 특징맵의 importance weight α^k 를 얻음.
- 이 α^k 와 특징맵 A^k 의 가중합을 통해 히트맵을 얻고, ReLU 활성화를 적용해 positive 영향 영역 만을 강조함

설명 가능한 AI(XAI)

3. Saliency Map

▶ Saliency Map

- 입력 이미지의 각 픽셀이 모델 출력에 얼마나 영향을 주는지 시각화하는 기법.
- 출력 확률을 기준으로 입력 픽셀의 기울기(gradient)를 계산함.
- 단순하지만 노이즈가 많고, 해석력이 떨어지는 단점이 있음.
- “모델이 어디를 보고 판단했는가?”를 기본적으로 보여줌.



설명 가능한 AI(XAI)

4. Integrated Gradients

▶ Intergrated Gradients

- 딥러닝 모델의 출력에 대한 입력 특징(feature)의 기여도를 정량적으로 계산하는 해석 기법임.
- 입력값과 기준값(예: 모든 0 이미지) 사이를 잇는 선형 경로를 따라 기울기(gradient)를 누적적으로 적분함.
- 각 입력 특징이 모델 결과에 얼마나 영향을 주었는지를 계산해 모델의 결정 근거를 시각적으로 설명함.
- Saliency Map보다 노이즈가 적고, 이론적으로 일관성(Completeness)이 보장됨.
- 이미지 분류나 탭 데이터 등에서 특징 중요도 분석(feature importance analysis)에 활용됨.
- 장점 : 수학적으로 명확하고 모델 재학습이 필요 없음.
- 단점 : 기준 입력(baseline)의 선택에 따라 결과가 달라질 수 있음.