

컴퓨터비전(AI응용)

객체검출 1_Two-Stage Detector

- 분류 (Classification)
- 객체 위치 파악(Localization)
- 객체 탐지(Object Detection)
- 객체 인식(Instance Segmentation)



Classification

이미지 전체에서 하나의 주요 객체가 무엇인지 판별합니다. 예를 들어, 고양이 사진을 보고 "고양이"라고 분류하는 작업입니다.



Object Detection

여러 객체를 동시에 찾아내고 각각을 분류합니다. Classification과 Localization을 동시에 수행하는 복합 태스크입니다.



Localization


단일 객체의 위치를 Bounding Box로 표현합니다. 객체가 이미지의 어디에 있는지 좌표로 나타냅니다.




Instance Segmentation

검출된 각 객체의 정확한 윤곽을 픽셀 단위로 분리합니다. 가장 세밀한 수준의 객체 인식 기술입니다.

- Classification: 이미지 내 Object의 class를 판별하는 것
- Localization: 이미지 내 Object의 위치를 찾아내는 것(Bounding box)
- Object detection: 두개 이상의 object들에 대해 Classification + Localization
- Instance Segmentation: object detection을 통해 찾아낸 object의 형상에 따라 각각의 object의 영역을 표시 (pixel에 대한 classification)





기술적 복잡성

- 이중 과제 수행: 분류와 위치 예측을 동시에 정확하게 처리해야 합니다
- 다양성 처리: 크기, 형태, 각도가 제각각인 객체들을 일관되게 검출해야 합니다
- 실시간 요구: 비디오나 자율주행과 같은 응용에서는 빠른 추론 속도가 필수적입니다

데이터와 환경

- 배경 처리: 이미지의 대부분이 배경인 경우 객체를 정확히 구분하기 어렵습니다
- 레이블링 비용: 각 객체마다 위치와 클래스를 표시하는 annotation 작업이 매우 시간 소모적입니다
- 가림 현상: 객체가 서로 겹치거나 일부만 보이는 상황에서도 정확히 검출해야 합니다

작동 방식

Window를 일정한 간격으로 이동시키면서 각 위치에서 객체 검출을 수행합니다. 다양한 크기와 종횡비의 window를 사용하여 여러 스케일의 객체를 찾아냅니다.

근본적 한계

이미지의 대부분은 배경이지만 모든 영역을 검사해야 하므로 계산량이 기하급수적으로 증가합니다. 실시간 처리가 거의 불가능하며, 효율성이 매우 낮습니다.

Window를 이동시키면서 object를 detection 하는 방식

- 다양한 형태의 window를 각각 sliding 시키는 방식
- Window scale은 고정하고 scale을 변경한 여러 이미지를 사용하는 방식
- Object Detection의 초기 기법으로 활용
- Object가 없는 영역도 sliding 해야하며, 여러 형태의 window / scale에 대한 고려 필요
(대부분이 background, computation load)



▶ Selective Search 알고리즘

객체가 있을 가능성이 높은 후보 영역(Region Proposal)만 추출하여 검사 효율을 획기적으로 높입니다. 모든 영역을 검사하는 대신 약 2000개의 유망한 영역만 선택합니다.



Over-segmentation

이미지를 색상과 질감 기반으로 매우 작은 영역들로 초기 분할합니다.



유사 영역 병합

컬러, 무늬, 크기, 형태가 유사한 인접 segment들을 반복적으로 그룹화합니다.



Region Proposal 생성


병합된 영역들을 Bounding Box로 변환하여 최종 후보 영역 목록을 생성합니다.

핵심 아이디어: 객체는 비슷한 특성을 가진 픽셀들이 모여 있다는 가정을 활용하여, 전체 이미지에서 객체가 있을 법한 위치를 지능적으로 추천합니다.


- Object가 있을 만한 후보 영역(bounding box)를 추출하는 알고리즘
 - Selective search, Edge boxes



원본 이미지



select



후보 bounding box 선택



최종 후보 도출



Object detection



Selective Search

- 빠른 Detection과 높은 Recall 예측 성능을 동시에 만족하는 알고리즘
- 컬러, 무늬, 크기, 형태에 따라 유사한 region을 grouping
- Selective Search 최초에는 pixel intensity 기반한 graph-based segment 기법에 따라 over segmentation 수행
(각각의 object들이 1개의 개별 영역에 담길 수 있도록 많은 초기 영역을 생성)
 1. 개별 segment된 모든 부분들을 bounding box로 만들어서 region proposal 리스트 추가
 2. 컬러 무늬, 크기, 형태에 따라 유사도가 비슷한 segment들을 grouping
 3. 다시 1번 step region proposal 리스트 추가
 4. 유사도가 비슷한 segment들 grouping을 계속 반복하면서 region proposal 수행



IoU: 검출 정확도 평가 핵심

- Intersection over Union: 모델이 예측한 결과와 Ground Truth 가 얼마나 겹치는지 나타내는 지표
Object detection에서 개별 object에 대한 detection 이 성공했는지 여부를 IOU로 판단
일반적으로 PASCAL VOC Challenge 에서는 **0.5 이상이면 예측 성공으로 판단**



Intersection over Union

IoU는 예측한 Bounding Box가 정답(Ground Truth)과 얼마나 잘 일치하는지를 0에서 1 사이의 값으로 나타냅니다.

계산 방식:

$$\text{IoU} = (\text{두 박스의 교집합 영역}) / (\text{두 박스의 합집합 영역})$$

값이 1에 가까울수록 완벽한 예측이며, 일반적으로 0.5 이상이면 성공적인 검출로 간주합니다.

평가 기준

- PASCAL VOC: $\text{IoU} \geq 0.5$ 를 기준으로 검출 성공 여부를 판단합니다
- MS COCO: IoU 0.5부터 0.95까지 여러 임계값을 사용하여 더 엄격하게 평가합니다

gIoU (Generalized IoU)


두 박스가 전혀 겹치지 않아 IoU가 0인 경우에도 거리 정보를 반영할 수 있도록 개선된 지표입니다. 두 박스를 감싸는 최소 박스 C를 고려하여 계산합니다.

$$\text{gIoU} = \text{IoU} - |C \setminus (A \cup B)| / |C|$$

Left_up



right_down

$[(x - 0.5 w), (y - 0.5 h)]$	$[(x + 0.5 w), (y + 0.5 h)]$
$[(x' - 0.5 w'), (y' - 0.5 h')]$	$[(x' + 0.5 w'), (y' + 0.5 h')]$




Generalized IOU

- 두 box간 교집합이 없으면, IOU는 0이 되므로 얼마나 오차가 있었는지 알기 어려운 점을 보완한 지표



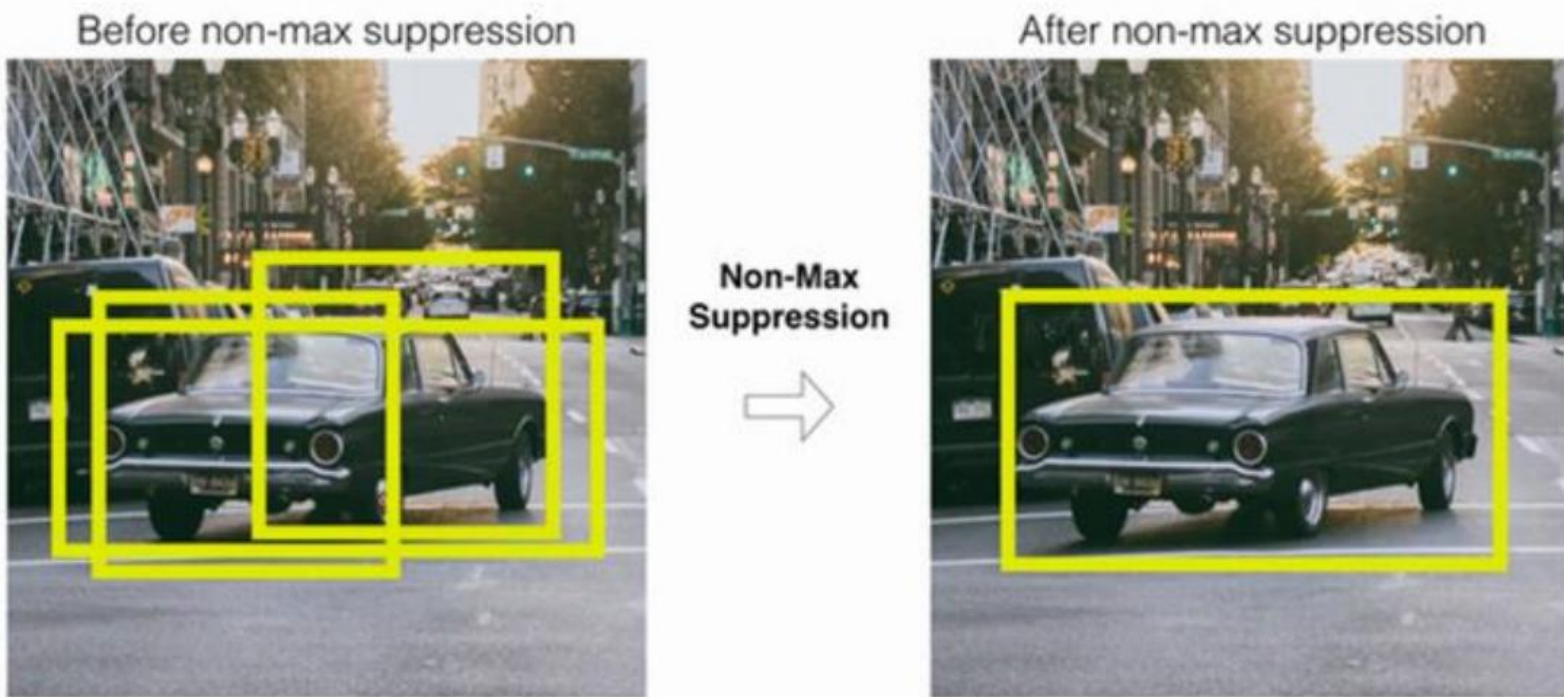
※C box: GT와 prediction을 포괄하는 가장 작은 박스

$$GIoU = \frac{|A \cap B|}{|A \cup B|} - \frac{|C \setminus (A \cup B)|}{|C|} = IoU - \frac{|C \setminus (A \cup B)|}{|C|}$$



NMS: 중복 검출 제거


- Object Detection 알고리즘은 object가 있을만한 위치에 많은 Detection을 수행하는 경향이 강함
- NMS는 Detect된 object의 bounding box 중에 비슷한 위치에 있는 box를 제거하고 가장 적합한 box를 선택하는 기법



NMS: 중복 검출 제거

1. Detect 된 bounding box 별로 특정 confidence threshold 이하 bounding box는 먼저 제거 (confidence < 0.5)
2. 가장 높은 confidence score 를 가진 box 순으로 내림차순 정렬 후,
아래 로직을 모든 box에 순차적으로 적용
→ 높은 confidence score를 가진 box와 겹치는 다른 box를 모두 조사하여 IOU가 특정 threshold 이상인 Box를 모두 제거 (IOU threshold >0.4)
3. 남아 있는 box만 선택

Confidence가 높을 수록,
IOU threshold가 낮을 수록
많은 box가 제거됨



- 하나의 객체에 대해 여러 개의 Bounding Box가 검출되는 경우가 많습니다.
- Non-Maximum Suppression은 이러한 중복을 제거하여 가장 확실한 하나의 박스만 선택하는 후처리 기법입니다.

01

Confidence 필터링

Confidence threshold(예: 0.5) 이하의 신뢰도가 낮은 박스들을 먼저 제거합니다.

02

정렬

남은 박스들을 Confidence score 기준으로 내림차순 정렬합니다.

03

반복 제거

가장 높은 confidence 박스를 선택하고, 이와 IoU가 threshold(예: 0.4) 이상인 박스들을 중복으로 간주하여 제거합니다.

04

최종 선택

모든 박스가 처리될 때까지 반복하여 최종적으로 중복이 제거된 박스들만 남깁니다.

조정 포인트: Confidence threshold를 높이면 검출 수가 줄어들고, IoU threshold를 낮추면 더 많은 중복 박스가 제거됩니다.

```
def nms(bboxes, iou_threshold, sigma=0.3):
    classes_in_img = list(set(bboxes[:, 5])) img의 여러 objects에서 img상 찾아낸 objects(0,1,2: (예)고양이, 개, 말 ) 남김(set())
    best_bboxes = []
```

```
for cls in classes_in_img:
    cls_mask = (bboxes[:, 5] == cls) 예, class가 0인 것만 추출, cls_bboxes 변수 생성
    cls_bboxes = bboxes[cls_mask]
    while len(cls_bboxes) > 0:
```

```
        max_ind = np.argmax(cls_bboxes[:, 4]) class bboxes의 score가 가장 큰 값을 max_ind 변수 생성
        best_bbox = cls_bboxes[max_ind]
        best_bboxes.append(best_bbox)
        cls_bboxes = np.concatenate([cls_bboxes[: max_ind], cls_bboxes[max_ind + 1:]])
```

```
        iou = bboxes_iou(best_bbox[np.newaxis, :4], cls_bboxes[:, :4])
        weight = np.ones((len(iou),), dtype=np.float32)
```

```
        iou_mask = iou > iou_threshold
        weight[iou_mask] = 0.0 best box와 겹치는 bound를 제거하기 위해 weight=0 부여
```

```
        cls_bboxes[:, 4] = cls_bboxes[:, 4] * weight
        score_mask = cls_bboxes[:, 4] > 0.
        cls_bboxes = cls_bboxes[score_mask]
```

```
return best_bboxes
```

	0	1	2	3	4	5
x	y	w	h	score	class	
				0.4	0	
						1
				0.7	0	
						2


Best box

best box 만 빼고 다 남겨서 cls_bboxes에 담기

mAP: 종합 성능 평가 지표

➤ Mean Average Precision

실제 object가 detect 된 재현율(recall)의 변화에 따른 정밀도 (Precision)를 평균한 성능 지표



mAP: 종합 성능 평가 지표

- Precision: 예측을 Positive로 한 대상 중에 예측과 실제 값이 Positive로 일치한 데이터의 비율
Object Detection에서는 검출 알고리즘이 검출 예측한 결과가 실제 object들과 얼마나 일치하는지 나타내는 지표
- Recall: 실제 값이 Positive인 대상 중에 예측과 실제 값이 Positive로 일치한 데이터의 비율
Object detection에서는 검출 알고리즘이 실제 object들을 빠뜨리지 않고 얼마나 정확히 검출 예측하는지 나타내는 지표

정확히 Bird로 예측
(Precision = 100%)



오른쪽 새는 예측 못함
(Recall = 50%)


mAP: 종합 성능 평가 지표

- Confusion Matrix : 이진 분류의 예측 오류가 얼마인지 더불어 어떠한 유형의 예측 오류가 발생하고 있는지 함께 나타내는 지표

		예측 클래스(Predicted Class)	
		Negative(0)	Positive (1)
실제 클래스 (Actual Class)	Negative(0)	Negative Negative (True Negative) TN	Negative Positive (False Positive) FP
	Positive(1)	Positive Negative (False Negative) FN	Positive Positive (True Positive) TP

▪ **Precision** : $TP / (FP + TP)$

▪ **Recall** : $TP / (FN + TP)$



➤ **Precision / Recall 의 상대적 중요도**

의료 영상 판별 : 재현율이 더 중요 (실제 Positive 양성인 데이터를 Negative로 판별할 경우 Risk가 큼)

스팸 메일 판별 : 정밀도가 더 중요 (실제 Negative인 데이터를 Positive로 판별할 경우 Risk가 큼)

➤ **Precision 100%**

확실한 기준이 되는 경우만 Positive로 예측하고 나머지는 모두 Negative로 예측

ex) 확실한 징후를 보이는 환자만 Positive로 판별하고, 나머지 환자는 모두 Negative

➤ **Recall 100%**

모든 가능한 후보들을 Positive로 예측

ex) 모든 환자들을 Positive로 예측 (실제 환자들이 모두 포함)

mAP: 종합 성능 평가 지표

- Confidence score: Bounding box안에 object가 있을 확률이 얼마나 되는지, 그리고 object가 class를 정확하게 예측했는지 나타내는 지표

$$Pr(Class_i | Object) * Pr(object) * IOU_{pred}^{truth} = Pr(Class_i) * IOU_{pred}^{truth}$$

- Confidence score에 따른 Precision Recall 변화 (Trade-off)



Confidence score가 낮을 수록
더 많은 bounding box를 만들게 되어
Precision은 낮아지고 Recall은 높아짐

Confidence score가 높을 수록
신중하게 예측 bounding box를 만들게 되어
Precision은 높아지고 Recall은 낮아짐



mAP: 종합 성능 평가 지표

- Precision-Recall Curve: Confidence 값에 따른 Recall 값에 대한 Precision값을 나타낸 곡선

Confidence: 0.9

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2

Precision = 1/1 , Recall = 1/5



Confidence: 0.8

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2
0.8	True	1.0	0.4


Precision = 2/2 , Recall = 2/5



Confidence : 0.7

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2
0.8	True	1.0	0.4
0.7	False	0.67	0.4


Precision = 2/3 , Recall = 2/5



Confidence: 0.6

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2
0.8	True	1.0	0.4
0.7	False	0.67	0.4
0.6	False	0.5	0.4

Precision = 2/4 , Recall = 2/5



mAP: 종합 성능 평가 지표

- Precision-Recall Curve: Confidence 값에 따른 Recall 값에 대한 Precision값을 나타낸 곡선

Confidence: 0.9

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2

Precision = 1/1 , Recall = 1/5



Confidence: 0.8

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2
0.8	True	1.0	0.4


Precision = 2/2 , Recall = 2/5



Confidence : 0.7

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2
0.8	True	1.0	0.4
0.7	False	0.67	0.4


Precision = 2/3 , Recall = 2/5



Confidence: 0.6

confidence	정확?	Precision	Recall
0.9	True	1.0	0.2
0.8	True	1.0	0.4
0.7	False	0.67	0.4
0.6	False	0.5	0.4

Precision = 2/4 , Recall = 2/5



평가 지표의 구성

Precision

예측한 것 중 정답의 비율

$$= TP / (TP + FP)$$

Recall

실제 객체 중 찾아낸 비율

$$= TP / (TP + FN)$$

Average Precision

Recall 변화에 따른 Precision의 평균값으로,
Precision-Recall 곡선 아래 면적을 나타냅니다.

mean Average Precision

mAP는 모든 클래스에 대한 AP의 평균값으로, 객체 검출 모델의 전체 성능을 하나의 숫자로 표현합니다.

- PASCAL VOC: mAP@0.5 - IoU 0.5를 기준으로 평가
- MS COCO: mAP@[0.5:0.95] - IoU 0.5부터 0.95까지 0.05 간격으로 평가한 평균값

COCO의 평가 방식이 더 엄격하기 때문에, 같은 모델이라도 COCO mAP가 PASCAL VOC mAP보다 낮게 나타납니다.

해석: mAP 값이 높을수록 모든 클래스에 대해 정확하고 빠짐없이 검출한다는 의미입니다.

▶ Two-Stage Detector는 객체 검출을 두 단계로 나누어 수행합니다.

- 1) 첫 번째 단계에서 Region Proposal을 생성
- 2) 두 번째 단계에서 각 영역을 분류하고 위치를 정제합니다

이러한 접근 방식은 정확도를 최우선으로 하며, R-CNN 계열이 대표적입니다.

처리 파이프라인

1. Selective Search: 이미지당 약 2000개의 region proposal 생성
2. CNN Feature 추출: 각 region을 고정 크기로 warp하여 AlexNet에 통과
3. SVM 분류: 추출된 feature로 객체 클래스 판별
4. Bounding Box Regression: 박스 위치를 정밀하게 조정

Bounding Box Regression

예측 박스(P)와 Ground Truth(G) 사이의 변환 관계식을 학습합니다. Scale을 고려한 offset을 예측하며, L2 정규화로 과적합을 방지합니다.

핵심 문제점

- 극도로 느린 속도: 2000개 region 각각에 대해 CNN을 실행하여 이미지당 47초 소요
- Multi-stage Training: CNN, SVM, Regressor를 따로 학습해야 하는 복잡한 과정
- 메모리 부담: 모든 region의 feature를 디스크에 저장해야 함
- End-to-end 불가: SVM과 regressor가 CNN feature를 업데이트하지 못함

의의: CNN을 객체 검출에 성공적으로 적용하여 딥러닝 기반 검출의 가능성을 보여준 선구적 연구입니다.


Fast R-CNN(2015) ROI Pooling 혁신

▶ 핵심 개선: 전체 이미지 CNN 1회 통과

- R-CNN의 가장 큰 비효율은 2000개 region 각각에 대해 CNN을 실행하는 것이었습니다.
- Fast R-CNN은 **전체 이미지를 CNN에 한 번만 통과시켜** feature map을 얻은 후, 이 공유된 feature map에서 각 region의 feature를 추출합니다.



서로 다른 크기의 region feature를 고정된 H×W 크기(예: 7×7)로 통일합니다. Feature map을 grid로 분할하고 각 cell에서 max pooling을 수행하여, 입력 크기와 무관하게 일정한 출력을 생성합니다.




Training 속도 향상

84시간 → 9.5시간



Testing 속도 향상

47초 → 0.32초



mAP 성능

66.0% → 66.9% (성능도 향상)

남은 병목: Selective Search가 여전히 CPU에서 이미지당 2초씩 소요되어 전체 파이프라인의 속도를 제한합니다.

Faster R-CNN (2015): 완전한 End-to-End

Region Proposal Network (RPN)

Faster R-CNN의 핵심 혁신은 Selective Search를 **학습 가능한 신경망(RPN)**으로 대체한 것입니다. 이로써 전체 검출 파이프라인이 하나의 통합된 네트워크가 되어 end-to-end 학습이 가능해 졌습니다.

Anchor Box 개념

Feature map의 각 위치마다 미리 정의된 여러 개의 참조 박스 (anchor)를 배치합니다.

- 3가지 크기: 128^2 , 256^2 , 512^2 픽셀
- 3가지 비율: 1:1, 1:2, 2:1
- 총 9개 조합: 각 위치에서 다양한 객체 검출 가능

Anchor는 검출하려는 객체의 초기 템플릿 역할을 하며, RPN은 이를 정제하여 정확한 proposal을 생성합니다.

RPN 구조

Feature map에서 3×3 conv로 sliding window를 수행하고, 각 위치의 9개 anchor에 대해:

- Classification: 2개 출력 (객체 있음 / 배경)
- Regression: 4개 출력 (x, y, w, h의 offset)

Joint Training: RPN과 Fast R-CNN을 함께 학습하여 4가지 loss를 동시에 최적화 합니다.

1. RPN classification loss (anchor 품질)
2. RPN regression loss (anchor $\rightarrow$ proposal)
3. Fast R-CNN classification loss (클래스 분류)
4. Fast R-CNN regression loss (proposal $\rightarrow$ bbox)

Faster R-CNN (2015): 완전한 End-to-End

Region Proposal Network (RPN)

[성과]

0.2초

Testing 시간

Fast R-CNN 대비 10배 개선

66.9%

mAP 유지

속도와 정확도 모두 확보

100%

End-to-End

완전한 통합 학습 가능

PASCAL VOC

- 클래스: 20개 (사람, 동물, 차량, 가구 등)
- 이미지 수: 약 20,000개 (train + val)
- 평균 객체 수: 2.4개/이미지
- 평가 기준: mAP@0.5
- 특징: 상대적으로 단순한 장면, 객체가 크고 명확함

MS COCO

- 클래스: 80개 (더 다양한 일상 객체)
- 이미지 수: 약 120,000개 (train + val)
- 평균 객체 수: 7.2개/이미지
- 평가 기준: mAP@[0.5:0.95]
- 특징: 복잡한 장면, 작은 객체, 가림 현상 많음

COCO는 더 어려운 검출 환경을 제공하여 모델의 실전 성능을 더 엄격하게 평가합니다. 같은 모델이라도 COCO mAP가 PASCAL VOC mAP보다 대체로 10-15% 정도 낮게 측정됩니다.

Two-Stage 철학

Region Proposal과 Classification을 분리하여 정확도를 최우선으로 추구합니다. 실시간성보다 정밀한 검출이 중요한 의료 영상, 보안 시스템 등에 적합합니다.

R-CNN의 진화

R-CNN → Fast R-CNN → Faster R-CNN으로 발전하며 속도는 수백 배 개선되었지만 정확도는 유지 또는 향상되었습니다. ROI Pooling과 RPN이 핵심 혁신입니다.

평가의 중요성

IoU, NMS, mAP는 객체 검출 모델을 이해하고 개선하는 데 필수적인 개념입니다. 각 지표의 의미와 조정 방법을 정확히 알아야 실무에서 활용할 수 있습니다.