

# 파이토치 딥러닝 프로그래밍

객체검출 1\_Two-Stage Detector

**▶ 컴퓨터 비전의 주요 태스크**

- 분류 (Classification)
- 객체 위치 파악(Localization)
- 객체 탐지(Object Detection)
- 객체 인식(Instance Segmentation)



### Classification

이미지 전체에서 하나의 주요 객체가 무엇인지 판별합니다. 예를 들어, 고양이 사진을 보고 "고양이"라고 분류하는 작업입니다.



### Object Detection

여러 객체를 동시에 찾아내고 각각을 분류합니다. Classification과 Localization을 동시에 수행하는 복합 태스크입니다.



### Localization

단일 객체의 위치를 Bounding Box로 표현합니다. 객체가 이미지의 어디에 있는지 좌표로 나타냅니다.



### Instance Segmentation

검출된 각 객체의 정확한 윤곽을 픽셀 단위로 분리합니다. 가장 세밀한 수준의 객체 인식 기술입니다.

## 기술적 복잡성

- 이중 과제 수행: 분류와 위치 예측을 동시에 정확하게 처리해야 합니다
- 다양성 처리: 크기, 형태, 각도가 제각각인 객체들을 일관되게 검출해야 합니다
- 실시간 요구: 비디오나 자율주행과 같은 응용에서는 빠른 추론 속도가 필수적입니다

## 데이터와 환경

- 배경 처리: 이미지의 대부분이 배경인 경우 객체를 정확히 구분하기 어렵습니다
- 레이블링 비용: 각 객체마다 위치와 클래스를 표시하는 annotation 작업이 매우 시간 소모적입니다
- 가림 현상: 객체가 서로 겹치거나 일부만 보이는 상황에서도 정확히 검출해야 합니다

## Intersection over Union

IoU는 예측한 Bounding Box가 정답(Ground Truth)과 얼마나 잘 일치하는지를 0에서 1 사이의 값으로 나타냅니다.

계산 방식:

$\text{IoU} = (\text{두 박스의 교집합 영역}) / (\text{두 박스의 합집합 영역})$

값이 1에 가까울수록 완벽한 예측이며, 일반적으로 0.5 이상이면 성공적인 검출로 간주합니다.

## 평가 기준

- PASCAL VOC:  $\text{IoU} \geq 0.5$ 를 기준으로 검출 성공 여부를 판단합니다
- MS COCO: IoU 0.5부터 0.95까지 여러 임계값을 사용하여 더 엄격하게 평가합니다

## gIoU (Generalized IoU)

두 박스가 전혀 겹치지 않아 IoU가 0인 경우에도 거리 정보를 반영할 수 있도록 개선된 지표입니다. 두 박스를 감싸는 최소 박스 C를 고려하여 계산합니다.

$$\text{gIoU} = \text{IoU} - |C \setminus (A \cup B)| / |C|$$

- 하나의 객체에 대해 여러 개의 Bounding Box가 검출되는 경우가 많습니다.
- Non-Maximum Suppression은 이러한 중복을 제거하여 가장 확실한 하나의 박스만 선택하는 후처리 기법입니다.

01

## Confidence 필터링

Confidence threshold(예: 0.5) 이하의 신뢰도가 낮은 박스들을 먼저 제거합니다.

02

## 정렬

남은 박스들을 Confidence score 기준으로 내림차순 정렬합니다.

03

## 반복 제거

가장 높은 confidence 박스를 선택하고, 이와 IoU가 threshold(예: 0.4) 이상인 박스들을 중복으로 간주하여 제거합니다.

04

## 최종 선택

모든 박스가 처리될 때까지 반복하여 최종적으로 중복이 제거된 박스들만 남깁니다.

조정 포인트: Confidence threshold를 높이면 검출 수가 줄어들고, IoU threshold를 낮추면 더 많은 중복 박스가 제거됩니다.

### 평가 지표의 구성

Precision

예측한 것 중 정답의 비율

$$= TP / (TP + FP)$$

Recall

실제 객체 중 찾아낸 비율

$$= TP / (TP + FN)$$

Average Precision

Recall 변화에 따른 Precision의 평균값으로,  
Precision-Recall 곡선 아래 면적을 나타냅니다.

### mean Average Precision

mAP는 모든 클래스에 대한 AP의 평균값으로, 객체 검출 모델의 전체 성능을 하나의 숫자로 표현합니다.

- PASCAL VOC: mAP@0.5 - IoU 0.5를 기준으로 평가
- MS COCO: mAP@[0.5:0.95] - IoU 0.5부터 0.95까지 0.05 간격으로 평가한 평균값

COCO의 평가 방식이 더 엄격하기 때문에, 같은 모델이라도 COCO mAP가 PASCAL VOC mAP보다 낮게 나타납니다.

해석: mAP 값이 높을수록 모든 클래스에 대해 정확하고 빠짐없이 검출한다는 의미입니다.

### 작동 방식

Window를 일정한 간격으로 이동시키면서 각 위치에서 객체 검출을 수행합니다. 다양한 크기와 종횡비의 window를 사용하여 여러 스케일의 객체를 찾아냅니다.

### 근본적 한계

이미지의 대부분은 배경이지만 모든 영역을 검사해야 하므로 계산량이 기하급수적으로 증가합니다. 실시간 처리가 거의 불가능하며, 효율성이 매우 낮습니다.

### ▶ Selective Search 알고리즘

객체가 있을 가능성이 높은 후보 영역(Region Proposal)만 추출하여 검사 효율을 획기적으로 높입니다. 모든 영역을 검사하는 대신 약 2000개의 유망한 영역만 선택합니다.



#### Over-segmentation

이미지를 색상과 질감 기반으로 매우 작은 영역들로 초기 분할합니다.



#### 유사 영역 병합

컬러, 무늬, 크기, 형태가 유사한 인접 segment들을 반복적으로 그룹화합니다.



#### Region Proposal 생성

병합된 영역들을 Bounding Box로 변환하여 최종 후보 영역 목록을 생성합니다.

핵심 아이디어: 객체는 비슷한 특성을 가진 픽셀들이 모여 있다는 가정을 활용하여, 전체 이미지에서 객체가 있을 법한 위치를 지능적으로 추천합니다.

▶ Two-Stage Detector는 객체 검출을 두 단계로 나누어 수행합니다.

- 1) 첫 번째 단계에서 Region Proposal을 생성
- 2) 두 번째 단계에서 각 영역을 분류하고 위치를 정제합니다

이러한 접근 방식은 정확도를 최우선으로 하며, R-CNN 계열이 대표적입니다.

## 처리 파이프라인

1. Selective Search: 이미지당 약 2000개의 region proposal 생성
2. CNN Feature 추출: 각 region을 고정 크기로 warp하여 AlexNet에 통과
3. SVM 분류: 추출된 feature로 객체 클래스 판별
4. Bounding Box Regression: 박스 위치를 정밀하게 조정

## Bounding Box Regression

예측 박스(P)와 Ground Truth(G) 사이의 변환 관계식을 학습합니다. Scale을 고려한 offset을 예측하며, L2 정규화로 과적합을 방지합니다.

## 핵심 문제점

- 극도로 느린 속도: 2000개 region 각각에 대해 CNN을 실행하여 이미 지당 47초 소요
- Multi-stage Training: CNN, SVM, Regressor를 따로 학습해야 하는 복잡한 과정
- 메모리 부담: 모든 region의 feature를 디스크에 저장해야 함
- End-to-end 불가: SVM과 regressor가 CNN feature를 업데이트하지 못함

의의: CNN을 객체 검출에 성공적으로 적용하여 딥러닝 기반 검출의 가능성을 보여준 선구적 연구입니다.


## Fast R-CNN(2015) ROI Pooling 혁신

### ▶ 핵심 개선: 전체 이미지 CNN 1회 통과

- R-CNN의 가장 큰 비효율은 2000개 region 각각에 대해 CNN을 실행하는 것이었습니다.
- Fast R-CNN은 **전체 이미지를 CNN에 한 번만 통과시켜** feature map을 얻은 후, 이 공유된 feature map에서 각 region의 feature를 추출합니다.



서로 다른 크기의 region feature를 고정된 H×W 크기(예: 7×7)로 통일합니다. Feature map을 grid로 분할하고 각 cell에서 max pooling을 수행하여, 입력 크기와 무관하게 일정한 출력을 생성합니다.




Training 속도 향상

84시간 → 9.5시간



Testing 속도 향상

47초 → 0.32초



mAP 성능

66.0% → 66.9% (성능도 향상)

남은 병목: Selective Search가 여전히 CPU에서 이미지당 2초씩 소요되어 전체 파이프라인의 속도를 제한합니다.

## Faster R-CNN (2015): 완전한 End-to-End

### Region Proposal Network (RPN)

Faster R-CNN의 핵심 혁신은 Selective Search를 **학습 가능한 신경망(RPN)**으로 대체한 것입니다. 이로써 전체 검출 파이프라인이 하나의 통합된 네트워크가 되어 end-to-end 학습이 가능해 졌습니다.

#### Anchor Box 개념

Feature map의 각 위치마다 미리 정의된 여러 개의 참조 박스 (anchor)를 배치합니다.

- 3가지 크기:  $128^2$ ,  $256^2$ ,  $512^2$  픽셀
- 3가지 비율: 1:1, 1:2, 2:1
- 총 9개 조합: 각 위치에서 다양한 객체 검출 가능

Anchor는 검출하려는 객체의 초기 템플릿 역할을 하며, RPN은 이를 정제하여 정확한 proposal을 생성합니다.

#### RPN 구조

Feature map에서  $3 \times 3$  conv로 sliding window를 수행하고, 각 위치의 9개 anchor에 대해:

- Classification: 2개 출력 (객체 있음 / 배경)
- Regression: 4개 출력 (x, y, w, h의 offset)

Joint Training: RPN과 Fast R-CNN을 함께 학습하여 4가지 loss를 동시에 최적화합니다.

1. RPN classification loss (anchor 품질)
2. RPN regression loss (anchor  $\rightarrow$  proposal)
3. Fast R-CNN classification loss (클래스 분류)
4. Fast R-CNN regression loss (proposal  $\rightarrow$  bbox)

## Faster R-CNN (2015): 완전한 End-to-End

### Region Proposal Network (RPN)

[ 성과 ]

0.2초

Testing 시간

Fast R-CNN 대비 10배 개선

66.9%

mAP 유지

속도와 정확도 모두 확보

100%

End-to-End

완전한 통합 학습 가능

## PASCAL VOC

- 클래스: 20개 (사람, 동물, 차량, 가구 등)
- 이미지 수: 약 20,000개 (train + val)
- 평균 객체 수: 2.4개/이미지
- 평가 기준: mAP@0.5
- 특징: 상대적으로 단순한 장면, 객체가 크고 명확함

## MS COCO

- 클래스: 80개 (더 다양한 일상 객체)
- 이미지 수: 약 120,000개 (train + val)
- 평균 객체 수: 7.2개/이미지
- 평가 기준: mAP@[0.5:0.95]
- 특징: 복잡한 장면, 작은 객체, 가림 현상 많음

COCO는 더 어려운 검출 환경을 제공하여 모델의 실전 성능을 더 엄격하게 평가합니다. 같은 모델이라도 COCO mAP가 PASCAL VOC mAP보다 대체로 10-15% 정도 낮게 측정됩니다.

### Two-Stage 철학

Region Proposal과 Classification을 분리하여 정확도를 최우선으로 추구합니다. 실시간성보다 정밀한 검출이 중요한 의료 영상, 보안 시스템 등에 적합합니다.

### R-CNN의 진화

R-CNN → Fast R-CNN → Faster R-CNN으로 발전하며 속도는 수백 배 개선되었지만 정확도는 유지 또는 향상되었습니다. ROI Pooling과 RPN이 핵심 혁신입니다.

### 평가의 중요성

IoU, NMS, mAP는 객체 검출 모델을 이해하고 개선하는 데 필수적인 개념입니다. 각 지표의 의미와 조정 방법을 정확히 알아야 실무에서 활용할 수 있습니다.