

컴퓨터비전(AI응용)

고급비전응용_의료영상분석

의료 영상 분석

- 의료 영상이란 무엇인가?
- AI가 왜 의료 영상 분석에 필요한가?
- 실제로 어떻게 구현하는가?

현재의 도전과제

- 매일 수천 장의 의료 영상 분석 필요
- 의사의 피로도 증가와 진단 시간 부족
- 미세한 병변 발견의 어려움
- 지역 간 의료 서비스 격차

AI의 역할

- 24시간 일관된 정확도로 1차 스크리닝
- 의사의 진단 보조 및 워크로드 감소
- 조기 발견을 통한 치료 성공률 향상
- 의료 접근성 향상

의료 AI는 의사를 대체하는 것이 아니라,

마치 숙련된 보조 의사처럼 위험 신호를 먼저 걸러내어 의사가 더 중요한 판단에 집중할 수 있도록 돕습니다.

01

환경 설정 및 기초 개념

PyTorch, DICOM 파일 구조,
의료 영상 데이터의 특성 이해

02

데이터 준비 및 전처리

Chest X-Ray 데이터셋 다운로드,
탐색, 정규화 및 증강 기법

03

모델 구축 및 학습

ResNet18 전이학습, 손실함수,
최적화 알고리즘 적용

04

평가 및 해석

성능 지표 분석, Grad-CAM을 통한 모델 설명 가능성 확보

05

고급 기법 및 보고서

ROC-AUC, Early Stopping, 실험 설정 자동 저장

이 강의는 초급 파트에서 기본 파이프라인을 완성한 후,
고급 파트에서 실제 연구 및 산업 현장에서 사용하는 정교한 평가 방법과 자동화 기술을 다룹니다.

DICOM

- Digital Imaging and Communications in Medicine의 약자
- 의료 영상과 관련 정보를 함께 저장하는 국제 표준 파일 형식입니다.
- 일반 이미지와의 차이
 - JPG/PNG: 사진 픽셀 정보만 포함
 - DICOM: 이미지 + 환자정보 + 촬영정보 + 장비정보 포함

DICOM 파일 구조

Header 정보

파일 식별자, 버전 정보

Meta Data

환자명, 나이, 성별, 촬영 날짜, 병원명,
장비 모델

Pixel Data

실제 의료 영상 픽셀 정보
(그레이스케일 또는 컬러)

Python

데이터 분석 및 머신러닝의 표준 언어

PyTorch

딥러닝 모델 구축을 위한 프레임워크

Google Colab

무료 GPU를 제공하는 클라우드 개발 환경

Kaggle

의료 영상 데이터셋을 제공하는 플랫폼

핵심 라이브러리 설치

기본 라이브러리

`torch`, `torchvision`: 딥러닝 모델 및 이미지 처리

`pydicom`: DICOM 파일 읽기 및 분석

`opendatasets`: Kaggle 데이터 다운로드

시각화 및 평가

`matplotlib`, `seaborn`: 그래프 시각화

`grad-cam`: 모델 해석 도구(XAI)

`scikit-plot`: ROC, PR Curve 등

- ❏ 재현성 확보: 모든 실험에서 동일한 결과를 얻기 위해 `torch.manual_seed()`로 랜덤 시드를 고정합니다.
이는 마치 요리 레시피를 정확히 따라서 항상 같은 맛을 내는 것과 같습니다.

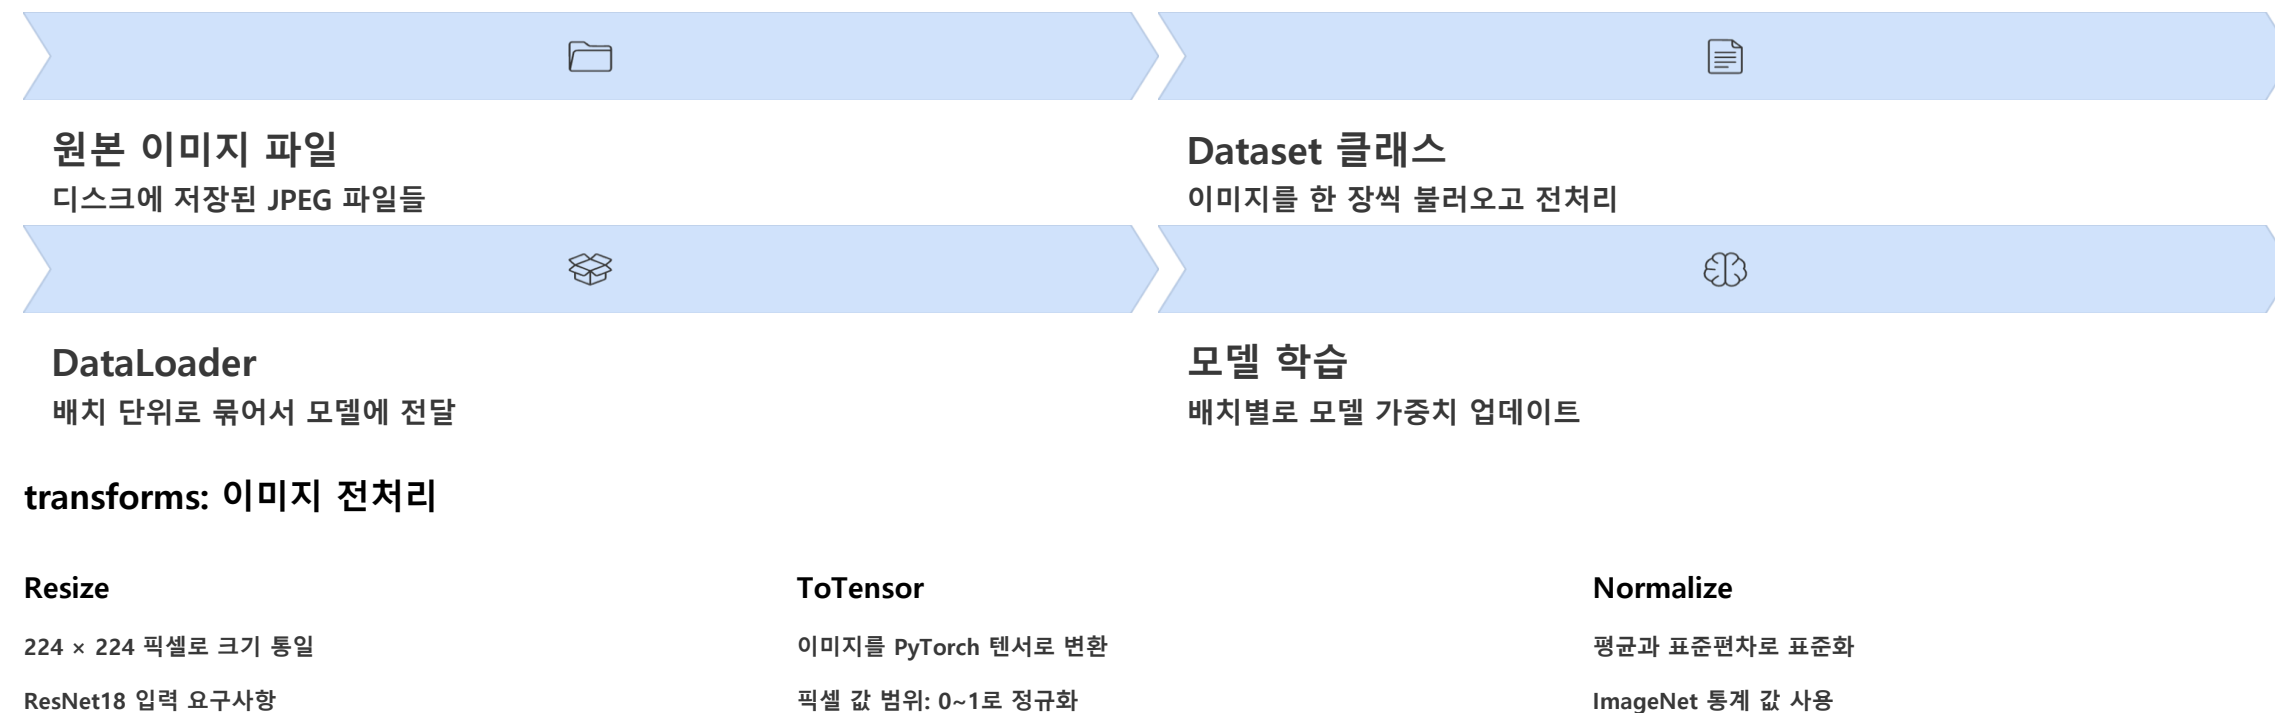
데이터셋 구조

1	2
NORMAL 클래스 정상 흉부 X-ray 이미지 훈련 데이터: 약 1,341장	PNEUMONIA 클래스 폐렴 진단 흉부 X-ray 이미지 훈련 데이터: 약 3,875장

데이터 특성

- 이미지 포맷: JPEG (DICOM 변환 완료)
- 그레이스케일 X-ray 영상
- 다양한 해상도 (전처리 필요)
- 클래스 불균형 존재 (PNEUMONIA 더 많음)

PyTorch 데이터 파이프라인



☐ 편의점 알바 비유: Dataset은 진열대에서 물건을 하나씩 꺼내는 것이고, DataLoader는 그 물건들을 카트에 32개씩 담아서 한 번에 계산대로 가져오는 것입니다. 배치 크기(batch size)가 바로 카트의 크기입니다.

ResNet18

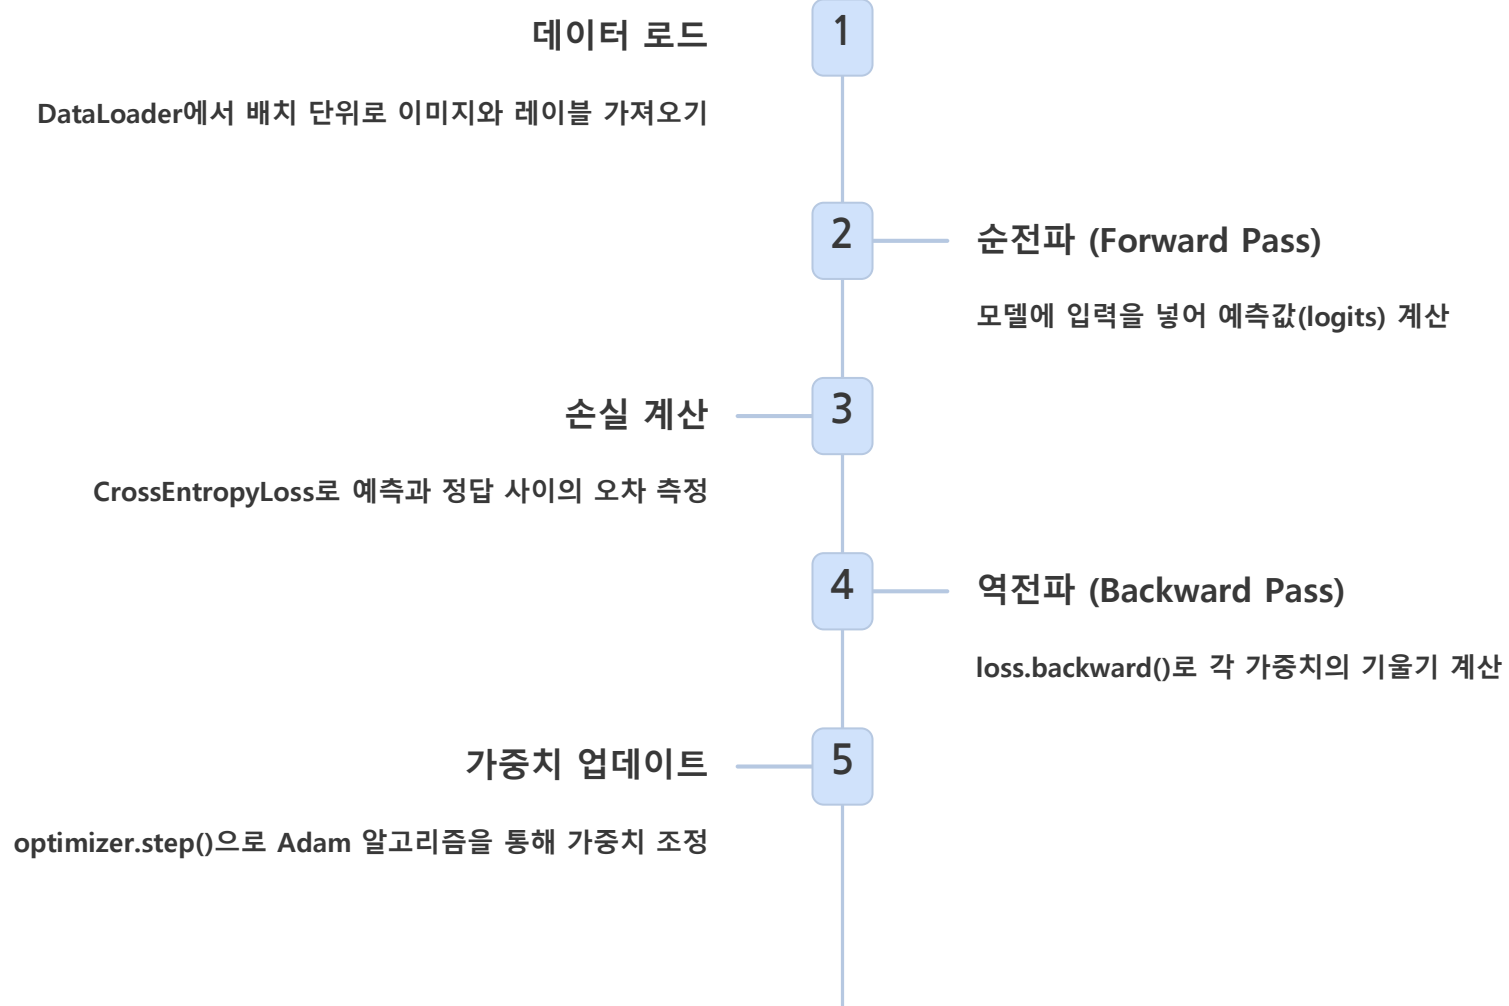
- ImageNet 사전학습 : 1,000개 클래스, 수백만 장의 일반 이미지로 이미 학습 완료
- 전이학습 적용 : 학습된 특징 추출 능력을 의료 영상에 재사용
- FC Layer 교체 : 마지막 출력층만 2개 클래스(NORMAL, PNEUMONIA)로 변경

FC Layer 교체 수식

- 기존 ImageNet 출력 차원 1000개를 우리 문제에 맞게 2개로 변경합니다:

$$\text{logits} = W \cdot x + b, \quad W \in \mathbb{R}^{2 \times d}$$

- 여기서 d 는 이전 레이어의 특징 벡터 차원이며, 최종 출력은 2차원(NORMAL, PNEUMONIA 각각의 점수)입니다.



CrossEntropyLoss 손실 함수

- 다중 클래스 분류 문제에서 가장 널리 사용되는 손실 함수입니다.
- 여기서 y_i 는 정답 레이블(one-hot), p_i 는 모델이 예측한 확률입니다.
정답 클래스의 확률을 1에 가깝게, 오답 클래스는 0에 가깝게 만들도록 학습합니다.

$$L = - \sum_i y_i \log(p_i)$$

주요 하이퍼파라미터

- Batch size: 32 (한 번에 처리할 이미지 수)
- Epoch: 10~20 (전체 데이터를 몇 번 반복)
- Learning rate: 0.001 (가중치 업데이트 보폭)

기본 평가 지표: 정확도 (Accuracy)

$$\text{Accuracy} = \frac{\text{올바르게 분류한 샘플 수}}{\text{전체 샘플 수}} = \frac{TP + TN}{TP + TN + FP + FN}$$

TP (True Positive)

폐렴을 폐렴으로 정확히 진단

TN (True Negative)

정상을 정상으로 정확히 진단

FP (False Positive)

정상인데 폐렴으로 오진 (거짓 양성)

FN (False Negative)

폐렴인데 정상으로 오진 (거짓 음성)

의료 AI에서 중요한 점

단순 정확도만으로는 충분하지 않습니다. 특히 의료 분야에서는 놓치지 않는 것(Recall)이 매우 중요합니다.

폐렴 환자를 정상으로 잘못 진단하면(FN) 치료 시기를 놓쳐 심각한 결과를 초래할 수 있기 때문입니다.

Grad-CAM

- Gradient-weighted Class Activation Mapping의 약자
- 딥러닝 모델이 이미지를 분류할 때 어느 영역을 중요하게 보았는지 히트맵(Heatmap)으로 시각화하는 설명 가능한 AI(XAI) 기법입니다.
- Grad-CAM 덕분에 블랙박스처럼 작동하던 AI 모델의 판단 근거를 의료진이 직접 검토할 수 있어, 임상 현장에서의 AI 도입에 큰 도움이 됩니다.

01

입력 이미지

흉부 X-ray 원본 이미지를 모델에 입력

02

모델 추론

ResNet18이 NORMAL 또는 PNEUMONIA로 분류

03

기울기 계산

예측 클래스에 대한 특정 레이어의 기울기 추출

04

히트맵 생성

중요 영역을 빨간색(높음)~파란색(낮음)으로 표시

05

원본 오버레이

히트맵을 원본 X-ray 위에 겹쳐서 시각화

연구 수준의 평가와 자동화

Train / Validation / Test 분할

검증셋(Validation set)을 도입하여 모델 선택과 하이퍼파라미터 튜닝을 수행하고, 최종 성능은 테스트셋으로만 평가합니다. 마치 모의고사(검증셋)로 실력을 점검한 후 진짜 시험(테스트셋)을 보는 것과 같습니다.

Early Stopping & LR Scheduler

Early Stopping은 검증 성능이 더 이상 개선되지 않으면 학습을 중단하여 과적합을 막습니다. Learning Rate Scheduler는 학습 초반에는 큰 걸음으로 빠르게 이동하고, 후반에는 작은 걸음으로 미세 조정하는 전략입니다.

고급 Grad-CAM (ScoreCAM, GradCAM++)

기본 Grad-CAM 외에도 ScoreCAM, GradCAM++ 같은 개선된 XAI 기법을 적용하여 더 안정적이고 정교한 시각화 결과를 얻습니다.

데이터 증강 (Data Augmentation)

RandomRotation, RandomHorizontalFlip 등을 통해 원본 이미지를 살짝 변형하여 학습 데이터의 다양성을 높입니다. 이는 과적합(Overfitting)을 방지하고 일반화 성능을 높이는 핵심 기법입니다.

ROC-AUC, Precision-Recall, F1-score

의료 AI에서는 정확도만으로 부족합니다. ROC 곡선, AUC, Precision-Recall 곡선, F1-score 등 다양한 지표를 종합적으로 분석하여 모델의 진단 성능을 다각도로 평가합니다.

실험 설정 JSON & 자동 보고서

학습 환경, 시간, 디바이스 정보를 JSON으로 저장하고, 최종 성능을 텍스트 보고서로 자동 생성합니다. 이는 재현 가능한 연구(Reproducible Research)의 핵심 요소입니다.

ROC Curve (Receiver Operating Characteristic Curve)

- 분류 모델의 성능을 시각화하는 그래프
- 민감도(Recall, TPR)와 거짓 양성률(FPR) 사이의 trade-off 를 보여줍니다.

주요 지표 정의

$$\text{TPR (민감도)} = \frac{TP}{TP + FN}$$

$$\text{FPR (거짓양성률)} = \frac{FP}{FP + TN}$$

TPR은 "실제 폐렴 환자 중 몇 %를 찾아냈는가", FPR은 "정상인 중 몇 %를 폐렴으로 오진했는가"를 나타냅니다.

AUC (Area Under Curve)


ROC 곡선 아래 면적으로, 0.5~1.0 범위를 가집니다.

AUC = 0.5: 동전 던지기 수준 (랜덤)

AUC = 0.7~0.8: 괜찮은 성능

AUC = 0.9 이상: 매우 우수한 성능

AUC = 1.0: 완벽한 분류기



의료 AI에서 AUC가 많이 사용되는 이유는, 클래스 불균형이 있어도 모델의 전반적인 분류 능력을 공정하게 평가할 수 있기 때문입니다.

의료 AI에서의 중요성

High Recall 중시 상황

암, 폐렴 같은 질병 스크리닝:
환자를 놓치면 안 됨 (FN 최소화)
정상인을 병으로 오진(FP)하는 것보다,
실제 환자를 놓치는 것(FN)이 훨씬 위험

High Precision 중시 상황

침습적 치료 결정: 잘못된 양성 진단이
큰 비용/부작용 초래
예: 수술이 필요한 경우, 오진으로 인한
불필요한 수술 방지

F1-score 균형

Precision과 Recall을 동시에 고려하여
균형 잡힌 성능 평가
하나만 높고 하나가 낮으면
F1-score도 낮아지므로, 전반적인 품질
지표로 활용

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$F1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$