

SSD (Single Shot MultiBox Detector)

실시간 객체 탐지를 가능하게 한 혁신적인 딥러닝 모델

SSD의 핵심 아이디어: Single Shot Detection

기존 방식의 한계

R-CNN 계열 모델들은 2단계 접근법을 사용했습니다. 먼저 Region Proposal로 후보 영역을 추출한 뒤, 각 영역에 대해 Feature Extraction과 Classification을 수행합니다. 이는 정확하지만 느리고 복잡한 프로세스였습니다.

SSD의 혁신

2016년에 발표된 SSD는 "Single Shot" 방식으로 한 번의 forward pass만으로 모든 객체를 동시에 탐지합니다. YOLO와 유사한 접근이지만, Multi-scale feature maps를 활용해 더 높은 정확도를 달성했습니다.

Multi-scale Feature Maps: SSD의 핵심 전략

SSD는 VGG-16 백본 네트워크를 통과하면서 생성되는 여러 크기의 feature map을 동시에 활용합니다. 이것이 다양한 크기의 객체를 효과적으로 탐지할 수 있는 핵심 비결입니다.

01

Conv4_3 (38×38)

고해상도 feature map으로 작은 객체를 탐지합니다. 보행자, 교통 표지판 등 세밀한 물체를 잡아냅니다.

02

Conv7 (19×19)

중간 해상도로 중간 크기 객체를 효과적으로 감지합니다.

03

Conv8_2 (10×10)

점차 감소하는 해상도에서 더 큰 물체를 탐지합니다.

04

Conv9_2 (5×5)

낮은 해상도에서 큰 객체의 전체적인 형태를 파악합니다.

05

Conv10_2 (3×3)

매우 낮은 해상도로 화면의 대부분을 차지하는 큰 객체를 탐지합니다.

06

Conv11_2 (1×1)

가장 낮은 해상도로 전체 이미지 수준의 매우 큰 객체를 감지합니다.

왜 Multi-scale이 중요한가?

작은 객체 탐지

고해상도 feature map(38×38)은 공간적 세부 정보를 보존하여 작은 객체의 미세한 특징을 잘 포착합니다. 멀리 있는 사람이나 작은 표지판도 놓치지 않습니다.

큰 객체 탐지

저해상도 feature map($3 \times 3, 1 \times 1$)은 넓은 수용 영역(receptive field)을 가져 큰 객체의 전체적인 맥락과 형태를 효과적으로 이해합니다.

다양성 확보

6개의 서로 다른 스케일을 사용함으로써 실제 세계의 다양한 크기의 객체들을 빠짐없이 탐지할 수 있습니다. 이것이 SSD의 강력한 범용성을 만듭니다.

Default Boxes (Anchor Boxes) 개념

SSD는 각 feature map의 각 위치마다 미리 정의된 Default Boxes를 설정합니다. 이는 Faster R-CNN의 anchor boxes와 유사한 개념입니다.

Default Box 설정

- 각 feature map 위치마다 4~6개의 default boxes 배치
- 다양한 aspect ratio 사용: 1:1, 2:1, 1:2, 3:1, 1:3 등
- 각 스케일마다 서로 다른 크기의 박스 적용
- 총 수천 개의 default boxes가 이미지 전체를 커버

각 default box는 실제 객체와의 매칭을 시도하며, IoU(Intersection over Union)가 높은 박스가 해당 객체를 담당하게 됩니다.

예측 메커니즘: 각 Default Box의 출력



클래스 점수 예측

C+1개의 클래스 확률을 출력합니다 (C개의 객체 클래스 + 1개의 배경 클래스). Softmax를 통해 각 박스가 어떤 객체를 포함하는지 판단합니다.



Offset 예측

4개의 offset 값 (dx, dy, dw, dh)을 예측하여 default box를 실제 객체 위치에 맞게 조정합니다. 이는 바운딩 박스의 정밀도를 크게 향상시킵니다.



후처리

NMS(Non-Maximum Suppression)로 중복된 탐지 결과를 제거하고, 신뢰도가 높은 최종 예측만을 남깁니다.

YOLO vs SSD: 실시간 탐지 모델 비교

특징	YOLO v1	SSD
Feature Map	단일 (7×7)	다중 (6개 레벨)
작은 객체 탐지	약함	강함
속도	매우 빠름	빠름
정확도	보통	높음
Anchor 전략	그리드 기반	Multi-scale default boxes

YOLO는 단일 feature map을 사용해 속도는 빠르지만 작은 객체 탐지에 약점이 있습니다. 반면 SSD는 Multi-scale 전략으로 속도와 정확도의 균형을 더 잘 맞춥니다. 특히 다양한 크기의 객체가 혼재된 실제 환경에서 SSD의 장점이 두드러집니다.

실제 동작 시나리오: 거리 장면 분석

보행자(작은 객체) + 자동차(큰 객체) 동시 탐지

1

Step 1: 고해상도 탐지

38×38 feature map에서 작은 보행자를 탐지합니다. 세밀한 공간 정보로 사람의 형태와 위치를 정확히 파악합니다.

2

Step 2: 저해상도 탐지

10×10 feature map에서 큰 자동차를 탐지합니다. 넓은 수용 영역으로 차량의 전체 형태를 인식합니다.

3

Step 3: 매칭 및 조정

각 feature map 위치의 default boxes와 실제 객체를 비교하여 IoU가 높은 박스를 선택하고 offset으로 정밀 조정합니다.

4

Step 4: 중복 제거

NMS(Non-Maximum Suppression)를 적용해 같은 객체에 대한 중복 탐지를 제거하고 최종 결과를 출력합니다.

SSD의 성능과 실용성

60

SSD300 FPS

300×300 입력 해상도에서 초당 약
60프레임 처리 가능 - 실시간 응용에
적합

22

SSD512 FPS

512×512 고해상도에서도 초당 22프
레이밍으로 빠른 속도 유지

6

Feature Scales

6개의 서로 다른 스케일로 다양한 크기
의 객체를 포괄적으로 커버

8732

Default Boxes

SSD300 기준 총 8,732개의 default
boxes로 촘촘한 객체 탐지 수행

이러한 성능 지표는 SSD가 자율주행, 영상 감시, 로봇 비전 등 실시간 처리가 필요한 다양한 분야에서 활용될 수 있음을 보여줍니다.

핵심 정리: SSD의 장단점

SSD의 장점

빠른 처리 속도

한 번의 forward pass로 모든 객체를 동시에 탐지하여 실시간 처리가 가능합니다.

Multi-scale 전략

6개 레벨의 feature maps로 작은 객체부터 큰 객체까지 다양한 크기를 효과적으로 탐지합니다.

End-to-End 학습

단순한 구조로 학습이 용이하며, Region Proposal 단계가 필요 없어 효율적입니다.

SSD의 단점

매우 작은 객체

Multi-scale을 사용하지만, 극단적으로 작은 객체는 여전히 탐지가 어렵습니다.

Default Box 의존성

Default box의 크기와 비율 설정이 성능에 큰 영향을 미치며, 데이터셋별 튜닝이 필요합니다.

클래스 불균형

대부분의 default boxes가 배경으로 분류되어 학습 시 클래스 불균형 문제가 발생할 수 있습니다.

질문이 있으신가요? SSD의 구조, 학습 방법, 또는 실제 구현에 대해 더 자세히 알고 싶으시면 언제든지 말씀해주세요!