

SSD Loss Function과 학습 메커니즘

Single Shot MultiBox Detector(SSD)는 객체 검출에서 속도와 정확도를 동시에 달성한 획기적인 모델입니다. 이 프레젠테이션에서는 SSD의 핵심인 Loss Function 구조와 학습 방법을 상세히 분석하여, 어떻게 수천 개의 default box에서 정확한 객체를 찾아내는지 살펴보겠습니다.

전체 Loss Function 구조

SSD의 학습은 두 가지 핵심 손실의 가중합으로 이루어집니다. Localization Loss는 박스의 위치를 정확하게 예측하도록 하고, Confidence Loss는 올바른 클래스를 분류하도록 학습시킵니다.

$$L(x, c, l, g) = \frac{1}{N} \times (L_{conf}(x, c) + \alpha \times L_{loc}(x, l, g))$$

여기서 N 은 매칭된 default box의 개수이며, α 는 두 손실 간의 균형을 조절하는 가중치입니다 (일반적으로 1.0).

주요 기호

- x : 매칭 indicator
- c : 클래스 신뢰도
- l : 예측 박스 위치
- g : Ground Truth
- α : 가중치



Localization Loss: 정확한 위치 예측

Localization Loss는 예측된 박스가 실제 객체의 위치를 얼마나 정확하게 포착하는지 측정합니다. 이는 매칭된 default box에 대해서만 계산되며, Smooth L1 함수를 사용하여 안정적인 학습을 보장합니다.

$$L_{loc}(x, l, g) = \sum_i \sum_j x_{ij} \times \text{Smooth}_{L1}(l_i - \hat{g}_j)$$

01

박스 인코딩

Ground Truth를 default box 기준 offset으로 변환

02

오차 계산

예측값과 인코딩된 GT 간의 차이 측정

03

Smooth L1 적용

안정적인 gradient를 위한 손실 함수 적용

박스 인코딩: Default Box 기준 변환

중심점 Offset

박스의 중심 좌표를 default box 대비 상대적 위치로 표현합니다. 이는 네트워크가 절대 좌표 대신 상대적 변화량을 학습하도록 합니다.

$$\hat{g}_j^{cx} = \frac{g_j^{cx} - d_i^{cx}}{d_i^w}$$
$$\hat{g}_j^{cy} = \frac{g_j^{cy} - d_i^{cy}}{d_i^h}$$

직관: default box에서 얼마나 이동해야 하는가?

크기 Offset

박스의 너비와 높이를 로그 스케일로 변환하여 다양한 크기의 객체를 효과적으로 표현합니다.

$$\hat{g}_j^w = \log \left(\frac{g_j^w}{d_i^w} \right)$$
$$\hat{g}_j^h = \log \left(\frac{g_j^h}{d_i^h} \right)$$

직관: default box 대비 몇 배 커지거나 작아지는가?

Smooth L1 Loss: 안정적인 학습의 핵심



L2 Loss의 문제

큰 오차가 발생하면 gradient가 폭발하여 학습이 불안정해집니다. Outlier에 과도하게 민감합니다.



L1 Loss의 문제

원점에서 미분 불가능하여 최적화가 어렵습니다. Gradient가 일정하여 세밀한 조정이 힘듭니다.



Smooth L1의 장점

작은 오차에는 L2, 큰 오차에는 L1을 적용하여 두 방식의 장점을 결합합니다.

$$\text{Smooth}_{L1}(x) = \begin{cases} 0.5 \times x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise} \end{cases}$$

Confidence Loss: 클래스 분류 학습

Confidence Loss는 각 default box가 어떤 클래스에 속하는지 정확하게 예측하도록 학습시킵니다. Softmax와 Cross Entropy를 사용하여 positive 샘플과 negative 샘플 모두에 대해 계산됩니다.

$$L_{conf}(x, c) = - \sum_i x_{ij}^p \times \log(\hat{c}_i^p) - \sum_i x_{ij}^0 \times \log(\hat{c}_i^0)$$



Positive Examples

실제 객체와 매칭된 default boxes. IoU > 0.5인 경우에 해당합니다.



Negative Examples


배경으로 분류된 default boxes. 대부분의 box가 여기에 속합니다.

Softmax 확률 계산

$$\hat{c}_i^p = \frac{\exp(c_i^p)}{\sum_p \exp(c_i^p)}$$

각 클래스에 대한 확률을 계산하고, Cross Entropy로 예측과 실제 레이블 간의 차이를 측정합니다.

Hard Negative Mining: 클래스 불균형 해결



문제 인식

수천 개의 default box 중 대부분이 배경입니다. Positive:Negative 비율이 1:100을 초과하여 심각한 클래스 불균형이 발생합니다.



Loss 계산 및 정렬

모든 negative 샘플의 confidence loss를 계산하고, 손실이 높은 순서대로 정렬합니다. 이는 학습이 어려운 샘플을 찾는 과정입니다.



Hard Negatives 선택

상위 K개의 hard negative만 선택하여 3:1 비율(negative:positive)을 유지합니다. 쉬운 배경은 무시하고 어려운 샘플에 집중합니다.

☐ 효과: 학습 효율이 크게 향상되고 수렴 속도가 빨라집니다. 객체와 유사한 패턴을 가진 어려운 배경에 집중하여 모델의 판별력이 향상됩니다.

Hard Negative Mining 작동 예시

10

Positive Examples

실제 객체와 매칭된 박스 수

8732

Negative Candidates

배경으로 분류된 전체 박스 수

30

Selected Hard Negatives

실제 학습에 사용되는 어려운 샘플

3:1

최종 비율

Negative와 Positive의 균형

선택 프로세스

```
# Step 1: 모든 negative의 loss 계산
neg_losses = compute_loss(all_negatives)
# 8732개의 loss 값

# Step 2: 상위 30개만 선택 (3:1 비율)
hard_negatives = top_k(neg_losses, k=30)

# Step 3: 최종 학습
final_loss = loss(10_positives) +
             loss(30_hard_negatives)
```

이 방법으로 쉬운 배경(빈 하늘, 단순한 벽)은 학습에서 제외하고, 객체와 비슷한 어려운 배경 패턴만 집중적으로 학습합니다.

전체 학습 프로세스

01

Forward Pass

입력 이미지를 네트워크에 통과시켜 모든 default box에 대한 예측을 생성합니다.

02

Box Matching

$IoU > 0.5$ 기준으로 default box와 Ground Truth를 매칭하여 positive 샘플을 결정합니다.

03

Hard Negative Mining

Negative 샘플 중 loss가 높은 상위 K개를 선택하여 3:1 비율을 유지합니다.

04

Loss 계산

Localization Loss와 Confidence Loss를 계산하고 가중합으로 total loss를 구합니다.

05

Backpropagation

계산된 loss를 역전파하여 네트워크 파라미터를 업데이트합니다.

핵심 포인트 요약



Multi-task Loss

위치 예측과 클래스 분류를 동시에 학습하여 end-to-end 최적화를 달성합니다. $\alpha=1.0$ 으로 두 손실의 균형을 유지합니다.



Smooth L1 Loss

작은 오차와 큰 오차에 각각 최적화된 손실 함수로 안정적이고 정확한 박스 회귀를 가능하게 합니다.



Hard Negative Mining

심각한 클래스 불균형 문제를 해결하고, 어려운 샘플에 집중하여 모델의 판별력을 향상시킵니다.



3:1 비율 유지

Negative와 Positive 샘플의 최적 비율을 유지하여 효율적이고 안정적인 학습을 보장합니다.

SSD의 Loss Function 설계는 객체 검출의 핵심 과제들을 우아하게 해결하며, 이러한 기법들은 현대 검출 모델의 기초가 되었습니다.