

강화 학습

1. 강화 학습 개요

1. 강화학습 개요

▶ 강화학습이란 ?

- 강화학습은 에이전트(Agent)가 환경(Environment)과 상호작용하며 보상(Reward)을 최대화하는 행동 전략을 스스로 학습하는 머신러닝 패러다임입니다.
- 지도학습과 달리 정답 레이블 없이 시행착오를 통해 학습하며, 게임 AI, 로봇 제어, 자율주행, 추천 시스템 등 다양한 분야에서 혁신적인 성과를 만들어내고 있습니다.

▶ 핵심 구성 요소

Agent: 환경에서 행동을 결정하는 학습 주체

Environment: 에이전트가 상호작용하는 외부 세계

Reward: 행동에 대한 피드백 신호

Policy: 상태에서 행동으로의 매핑 전략

▶ 실제 적용 사례

- 게임 AI :
 - AlphaGo는 DQN과 몬테카를로 트리 탐색을 결합하여 세계 최고 바둑 기사를 이겼습니다. Atari 게임에서도 인간 수준 이상의 성능을 달성했습니다.
- 로봇 제어 :
 - 산업용 로봇의 조립 작업, 물체 파지, 이동 경로 최적화에 강화학습이 활용되어 효율성과 정확도를 크게 향상시켰습니다.
- 자율 주행 :
 - 복잡한 교통 상황에서의 의사결정, 차선 변경, 장애물 회피 등 실시간 제어 문제를 강화학습으로 해결합니다.
- 추천 시스템 :
 - 사용자의 장기적인 만족도를 최대화하기 위해 콘텐츠, 광고, 제품 추천에 강화학습 기반 개인화 알고리즘을 적용합니다.

강화 학습

2. MDP: 의사결정 문제의 수학적 모델

2. MDP: 의사결정 문제의 수학적 모델

▶ MDP

- Markov Decision Process는 강화학습 문제를 수학적으로 정의하는 프레임워크입니다.
- 현재 상태 만으로 미래를 예측할 수 있다는 Markov 속성을 가정합니다.



State (S)

에이전트가 관찰하는 환경의 현재 상황. 예: CartPole의 각도와 속도



Action (A)

에이전트가 선택할 수 있는 행동의 집합. 예: 왼쪽/오른쪽 이동



Reward (R)

특정 행동의 즉각적인 보상. Policy 학습의 피드백 신호 역할



Transition (P)

행동에 따른 다음 상태로의 전이 확률. $P(s'|s,a)$ 형태로 표현



Discount Factor (γ)

미래 보상의 현재 가치를 결정하는 0~1 사이의 값. 장기적 전략 수립

강화 학습

3. Value Function과 Bellman Equation

3. Value Function과 Bellman Equation

▶ 가치 함수의 개념

- Value Function은 특정 상태 또는 상태-행동 쌍이 얼마나 좋은지를 나타내는 기대 누적 보상입니다.
- $V(s)$: 상태 s 에서 정책 π 를 따를 때의 기대 수익
- $Q(s,a)$: 상태 s 에서 행동 a 를 취한 후 정책 π 를 따를 때의 기대 수익

▶ Bellman 방정식

- 현재 가치와 미래 가치의 재귀적 관계를 정의합니다:

$$V(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V(s')]$$

- 이 방정식은 최적 정책을 찾기 위한 모든 RL 알고리즘의 수학적 기반입니다.

강화 학습

4. OpenAI Gym

▶ Gym


- Gym은 강화학습 알고리즘을 개발하고 비교하기 위한 표준화된 환경 라이브러리입니다.
- 다양한 난이도의 문제를 제공하여 학습자와 연구자가 쉽게 실험할 수 있습니다.



FrozenLake

4x4 또는 8x8 격자에서 시작 지점에서 목표 지점까지 안전하게 이동하는 문제입니다. 얼음 구멍(H)을 피하고 목표(G)에 도달하면 +1 보상을 받습니다.

- State: 16개 또는 64개 위치
- Action: 상하좌우 4방향
- 확률적 전이(미끄러짐)



CartPole

카트 위의 막대를 수직으로 유지하는 고전적인 제어 문제입니다. 막대가 쓰러지지 않고 오래 버틸수록 높은 보상을 받습니다.

- State: 위치, 속도, 각도, 각속도(4차원 연속)
- Action: 왼쪽/오른쪽 힘 적용
- Episode 길이 500 step 목표

강화 학습

5. 탐색과 활용의 딜레마

5. 탐색과 활용의 딜레마

강화학습의 핵심 과제는 알려진 좋은 행동을 활용(Exploitation)하면서 동시에 더 나은 행동을 탐색(Exploration)하는 균형을 맞추는 것입니다.



탐색 (Exploration)

새로운 상태와 행동을 시도하여 환경에 대한 지식을 확장합니다. 초기 학습 단계에서 중요합니다.



활용 (Exploitation)

현재까지 학습한 정보를 바탕으로 최선의 행동을 선택하여 보상을 최대화합니다.

ϵ -greedy Policy

가장 널리 사용되는 탐색 전략입니다. ϵ 확률로 무작위 행동을 선택하고, $(1-\epsilon)$ 확률로 현재 최선의 행동을 선택합니다.

- 초기에는 높은 ϵ 값(0.9~1.0)으로 적극 탐색
- 학습이 진행되며 ϵ 를 점진적으로 감소(decay)
- 최종적으로 낮은 ϵ 값(0.01~0.1)으로 수렴하여 주로 활용

강화 학습

6. Q-learning

▶ Q-learning

- Q-learning은 각 상태-행동 쌍의 가치(Q-value)를 테이블에 저장하고 반복적으로 업데이트하여 최적 정책을 학습하는 off-policy 알고리즘입니다.

1. Q-table 초기화

모든 상태-행동 쌍의 Q-value를 0 또는 작은 무작위 값으로 설정

2. 행동 선택

ϵ -greedy 정책으로 탐색과 활용의 균형을 맞추며 행동 선택

3. Q-value 업데이트

Bellman 방정식에 따라 $Q(s,a)$ 값을 점진적으로 개선

4. 수렴

충분한 반복 후 Q-table이 최적 가치 함수에 근사

□ Q-learning 업데이트 규칙

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

여기서 α 는 학습률(learning rate), γ 는 할인 계수(discount factor)입니다. 학습률은 새로운 정보를 얼마나 빠르게 반영할지를 결정하며, 할인 계수는 미래 보상의 중요도를 조절합니다.

강화 학습

7. Deep Q-Network



DQN

- Deep Q-Network는 Q-learning의 테이블을 신경망으로 대체하여 고차원 상태 공간 문제를 해결합니다. Atari 게임에서 인간 수준 성능을 달성하며 딥러닝 기반 강화학습 시대를 열었습니다.



Experience Replay

과거 경험을 메모리에 저장하고 무작위로 샘플링하여 학습. 데이터 간 상관관계를 제거하고 학습 안정성을 높입니다.



Target Network

일정 주기마다 업데이트되는 별도의 네트워크로 목표값 계산. 학습 과정의 발산을 방지합니다.



Deep Neural Network

다층 신경망으로 Q-function 근사. 복잡한 패턴과 고차원 입력(이미지 등)을 효과적으로 처리합니다.

Loss Function

$$L(\theta) = E_{(s,a,r,s') \sim D} [(r + \gamma \max_a Q(s', a'; \theta^-) - Q(s, a; \theta))^2]$$

여기서 θ 는 현재 네트워크 파라미터, θ^- 는 Target Network 파라미터, D 는 Replay Buffer입니다.

▶ CartPole DQN 실습 구조



환경 및 하이퍼파라미터 설정

Gymnasium으로 CartPole-v1 환경 생성, 학습률(0.001), 배치 크기(64), 버퍼 크기(10,000) 등 설정



DQN 모델 정의

PyTorch로 4차원 입력(state), 2개 은닉층(128, 128 units), 2차원 출력(Q-values) 구조 구현



Replay Buffer 구현

(state, action, reward, next_state, done) 튜플을 저장하고 랜덤 샘플링하는 메모리 클래스 작성



학습 루프 실행

Episode별 상호작용, ϵ -greedy 행동 선택, Q-network 업데이트, Target network 동기화 반복



결과 시각화

Episode별 reward, 이동 평균, 성공률 그래프를 matplotlib으로 생성하여 학습 과정 분석

강화 학습

8. 강화학습의 한계

8. 강화학습의 한계

▶ 기술적 한계

- 샘플 효율성
 - 수백만 번의 상호작용이 필요하여 실제 환경 적용이 어려울 수 있습니다.
- 보상 함수 설계
 - 잘못된 보상은 의도치 않은 행동을 유발할 수 있습니다(reward hacking).
- 안정성 문제
 - 학습 과정이 불안정하고 하이퍼파라미터에 민감합니다.

▶ 윤리와 안전

- 안전성 보장
 - 탐색 중 위험한 행동을 방지하는 안전 제약이 필수적입니다.
- 편향과 공정성
 - 학습 데이터의 편향이 의사결정에 반영될 수 있습니다.
- 투명성과 설명가능성
 - 복잡한 신경망 정책의 결정 과정을 이해하고 설명하기 어렵습니다.

강화학습을 실제 시스템에 배포할 때는 충분한 시뮬레이션 검증, 점진적 롤아웃, 지속적인 모니터링이 필요합니다. 기술의 발전만큼이나 책임 있는 개발과 운영이 중요합니다.

추천 참고 문헌

Sutton & Barto, *Reinforcement Learning: An Introduction* (2nd Edition) - RL의 바이블

- OpenAI Gym / Gymnasium Documentation - 실습 환경 공식 가이드
- Mnih et al., "Playing Atari with Deep Reinforcement Learning" - DQN 원논문